# 硕士学位论文

# 面向自动驾驶三维目标感知的在线与离线算法研究

# ONLINE AND OFFLINE ALGORITHMS FOR 3D OBJECT PERCEPTION IN AUTONOMOUS DRIVING

研　　究　　生：黄珂邈
指　导　教　师：郝祁副教授

南方科技大学
二〇二三年六月

国内图书分类号：TP183　　学校代码：14325
国际图书分类号：004.8　　密级：公开

工学硕士学位论文

# 面向自动驾驶三维目标感知的在线与离线算法研究

学 位 申 请 人：黄珂邈
指 导 教 师：郝祁副教授
副 指 导 教 师：张美莹研究助理教授
学 科 名 称：电子科学与技术
答 辩 日 期：2023 年 5 月
培 养 单 位：计算机科学与工程系
学位授予单位：南方科技大学

Classified Index: TP183
U.D.C: 004.8

Thesis for the degree of Master of Engineering

# ONLINE AND OFFLINE ALGORITHMS FOR 3D OBJECT PERCEPTION IN AUTONOMOUS DRIVING

| | |
|---|---|
| **Candidate:** | Huang Kemiao |
| **Supervisor:** | Associate Prof. Hao Qi |
| **Associate Supervisor:** | Research Assistant Prof. Zhang Meiying |
| **Discipline:** | Electronic Science and Technology |
| **Date of Defence:** | May, 2023 |
| **Affiliation:** | Department of Computer Science and Engineering |
| **Degree-Conferring-Institution:** | Southern University of Science and Technology |

# 学位论文公开评阅人和答辩委员会名单

公开评阅人名单

答辩委员会名单

# 南方科技大学学位论文原创性声明和使用授权说明

## 南方科技大学学位论文原创性声明

本人郑重声明：所提交的学位论文是本人在导师指导下独立进行研究工作所取得的成果。除了特别加以标注和致谢的内容外，论文中不包含他人已发表或撰写过的研究成果。对本人的研究做出重要贡献的个人和集体，均已在文中作了明确的说明。本声明的法律结果由本人承担。

作者签名：　　日期：

## 南方科技大学学位论文使用授权书

本人完全了解南方科技大学有关收集、保留、使用学位论文的规定，即：

1. 按学校规定提交学位论文的电子版本。

2. 学校有权保留并向国家有关部门或机构送交学位论文的电子版，允许论文被查阅。

3. 在以教学与科研服务为目的前提下，学校可以将学位论文的全部或部分内容存储在有关数据库提供检索，并可采用数字化、云存储或其他存储手段保存本学位论文。

（1）在本论文提交当年，同意在校园网内提供查询及前十六页浏览服务。

（2）在本论文提交 □ 当年/ □ 一年以后，同意向全社会公开论文全文的在线浏览和下载。

4. 保密的学位论文在解密后适用本授权书。

作者签名：　　日期：

指导教师签名：　　日期：

# 摘 要

作为自动驾驶感知技术的重要组成部分，三维目标检测与多目标跟踪技术一直以来受到业界广泛关注，其在线算法应用于驾驶过程中的障碍物感知，其离线算法应用于数据的自动化标注。实现安全的自动驾驶要求在线感知模块同时达到较高的准确性、实时性和鲁棒性。为了解决驾驶场景的复杂性和天气的多样性问题，使用相机和激光雷达等多种传感器进行优势互补是行业的主流方案。同时，对多任务使用统一的模型架构能够降低感知系统的复杂程度和开发成本。此外，在三维目标感知数据集自动标注过程中，针对多目标跟踪的离线优化是提高标注质量的重要环节，而目前行业内此类研究尚未形成范式。本文结合最新相关工作，探索使用深度学习、计算机视觉等方法等解决上述三维目标检测与跟踪的应用难题。本工作的主要创新点包括：（1）结合三维目标检测网络和多目标跟踪网络实现高效的多模态三维目标检测与跟踪；（2）结合外貌信息和运动信息对三维目标实现鲁棒的相似性计算；（3）结合目标检测不确定性和轨迹进入-退出概率实现综合的数据关联；（4）结合点级别的映射和测试时间增强实现精细的多模态感知结果集成；（5）结合正向与反向的跟踪结果实现准确的离线轨迹融合与优化。在公开数据集上的实验结果表明，本文提出的在线多目标跟踪方法在跟踪准确度和实时性上具有优越性，离线多目标跟踪方法在跟踪准确度上具有优越性且在系统架构上具有可拓展性。

**关键词**：三维目标检测；多目标跟踪；多模态传感器融合；自动标注算法

# Abstract

As crucial components of autonomous driving perception technology, 3D object detection and multi-object tracking has gained significant interest in the industry. The online algorithms are applied to the perception of obstacles during driving, while the offline algorithms are applied to the automatic data annotation. The online perception module is required to achieve high accuracy, real-time performance and robustness. To tackle the problems of complex driving scenes and diverse weather, camera-LiDAR fusion is the mainstream solution in the industry. In the mean time, applying a unified model architecture for multi-tasking can reduce the computational complexity and development cost of the perception system. Furthermore, the offline refinement for 3D multi-object tracking is an important stage during automatic dataset annotation for 3D object perception. However, there is no clear paradigm for it in academia. Based on the related work, this paper explores the application of deep learning and computer vision methods to solve the above challenges of 3D object detection and tracking. The novelty of this work includes: (1) integrating 3D object detection network and multi-object tracking network to achieve efficient join detection and tracking with multi-modality; (2) Combining appearance and motion cues to achieve robust affinity computation for 3D objects; (3) Using detection uncertainties, object affinities, and entry-exit probabilities to achieve comprehensive cross-frame data association; (4) Using point-wise correspondences and test-time augmentation techniques to achieve the fine ensemble of multi-modal perception results; (5) Combining forward and backward tracking results to achieve accurate trajectory fusion and refinement. The experiment results on the public dataset shows that the proposed online multi-object tracking method is superior in terms of tracking accuracy and real-time performance, and the proposed offline multi-object tracking method is superior in terms of tracking accuracy and system scalability.

**Keywords:** 3D object detection; multi-object tracking; multi-modal sensor fusion; auto-labeling algorithm

# 目 录

**摘 要**.....I
Abstract.....II
**符号和缩略语说明**.....V
**第 1 章 绪论**.....1
1.1 研究背景与意义.....1
1.2 研究现状.....3
1.2.1 图像和点云的特征提取.....5
1.2.2 图像特征的三维立体转化.....7
1.2.3 图像-点云的跨模态融合与时序融合.....8
1.2.4 三维目标检测架构.....10
1.2.5 在线多目标跟踪架构.....12
1.2.6 离线三维目标自动标注算法.....16
1.3 本工作的主要内容与贡献.....19
1.4 论文结构安排.....19
**第 2 章 三维目标检测与多目标跟踪基础理论**.....21
2.1 引言.....21
2.2 相机图像与激光点云的几何对应.....21
2.3 卡尔曼滤波器的运动预测和更新.....22
2.4 指派问题与匈牙利算法.....23
2.5 目标检测评价指标.....23
2.6 多目标跟踪评价指标.....24
2.7 在线多目标跟踪的轨迹管理.....26
**第 3 章 联合三维多目标检测与跟踪：JMODT**.....28
3.1 引言.....28
3.2 系统架构.....29
3.2.1 三维目标检测网络：EPNet.....30
3.2.2 问题描述.....33
3.3 本章提出的方法.....33
3.3.1 平行的目标检测与相关.....33

3.3.2 目标相似性计算.....35
3.3.3 基于 0-1 混合整数规划的数据关联.....36
3.4 实验验证.....37
3.4.1 数据集.....37
3.4.2 具体实现.....38
3.4.3 消融实验.....38
3.4.4 案例分析.....39
3.4.5 测试结果.....41
3.5 本章小结.....42
**第 4 章 三维多目标跟踪的离线优化**.....43
4.1 引言.....43
4.2 系统架构.....44
4.2.1 问题描述.....45
4.3 本章提出的方法.....45
4.3.1 三维目标检测的测试时间增强.....45
4.3.2 二维实例与三维目标检测的集成.....46
4.3.3 稳定的在线多目标跟踪.....47
4.3.4 正反双向轨迹的拆分与合并.....48
4.3.5 轨迹的修正与补全.....48
4.4 实验验证.....50
4.4.1 数据集.....50
4.4.2 具体实现.....51
4.4.3 消融实验.....52
4.4.4 与最新方法的比较.....53
4.5 本章小结.....53
**结 论**.....55
**参考文献**.....58
**致 谢**.....67
**个人简历、在学期间完成的相关学术成果**.....68

# 符号和缩略语说明

| | |
|---|---|
| AP | 平均精度（Average Precision） |
| AssA | 关联准确度（Association Accuracy） |
| AT | 额外训练（Additional Training） |
| BEV | 鸟瞰视角（Bird's Eye View） |
| CNN | 卷积神经网络（Convolutional Neural Network） |
| CVA | 速度恒定假设（Constant Velocity Assumption） |
| DetA | 检测准确度（Detection Accuracy） |
| DL | 深度学习（Deep Learning） |
| FP | 假阳性（False Positive） |
| FPA | 假阳关联（False Positive Association） |
| FN | 假阴性（False Negative） |
| FNA | 假阴关联（False Negative Association） |
| GPS | 全球定位系统（Global Position System） |
| GPU | 图形处理器（Graphics Processing Unit） |
| GRU | 门控循环单元（Gated Recurrent Unit） |
| GT | 地面真值（Ground Truth） |
| HA | 匈牙利算法（Hungarian Algorithm） |
| HOTA | 更高阶的跟踪准确度（Higher Order Tracking Accuracy） |
| IDSW | 身份交换（Identity Switch） |
| IMU | 惯性测量单元（Inertial Measurement Unit） |
| IoU | 交集除以并集（Intersection-over-Union） |
| IPM | 逆投影映射（Inverse Projection Mapping） |
| JDE | 联合检测与内嵌（Joint Detection and Embedding） |
| JDT | 联合检测与跟踪（Joint Detection and Tracking） |
| KF | 卡尔曼滤波器（Kalman Filter） |
| LSTM | 长短期记忆（Long Short Term Memory） |
| mAP | 平均精度均值（mean Average Precision） |
| MIP | 混合整数规划（Mixed Integer Programming） |
| ML | 大部分丢失（Mostly Lost） |
| MLP | 多层感知机（Multi-Layer Perceptron） |
| MOT | 多目标跟踪（Multi-Object Tracking） |

| | |
|---|---|
| MOTA | 多目标跟踪准确度（Multi-Object Tracking Accuracy） |
| MOTP | 多目标跟踪精确度（Multi-Object Tracking Precision） |
| MT | 大部分跟踪（Mostly Tracked） |
| MTL | 多任务学习（Multi-Task Learning） |
| NMS | 非极大值抑制（Non-Max Suppression） |
| PT | 部分跟踪（Partly Tracked） |
| ReID | 重识别（Re-Identification） |
| R-CNN | 基于区域的卷积神经网络（Region-based Convolutional Neural Network） |
| RoI | 感兴趣区域（Region of Interest） |
| RPN | 区域候选网络（Region Proposal Network） |
| RT | 运行时间（Run-Time） |
| SOT | 单目标跟踪（Single Object Tracking） |
| TBD | 基于检测的跟踪（Tracking-By-Detection） |
| TP | 真阳性（True Positive） |
| TPA | 真阳关联（True Positive Association） |
| TTA | 测试时间增强（Test-Time Augmentation） |

# 第 1 章　绪论

## 1.1　研究背景与意义

随着机器人技术与人工智能的发展，作为交叉领域的自动驾驶技术成为了当前的研究热点，并拥有广阔的前景和商业价值。2020 年，国务院发布《新能源汽车产业发展规划（2021—2035 年）》[1]，提出了对我国新能源汽车和自动驾驶汽车的愿景：2025 年高度自动驾驶汽车实现限定区域和特定场景商业化应用，并在 2035 年实现规模化应用。在“2020 世界智能网联汽车大会”上发布了《智能网联汽车技术路线图 2.0》[2]，共有三个关键时间节点：到 2025 年，部分自动驾驶和有条件自动驾驶的智能网联汽车市场份额超过 50%，高度自动驾驶的智能网联汽车实现限定区域和特定场景商业化应用；到 2030 年，部分自动驾驶和有条件自动驾驶的智能网联汽车市场份额超过 70%，高度自动驾驶的智能网联汽车市场份额达到 20%，并在高速公路广泛应用、在部分城市道路规模化应用；到 2035 年，中国方案智能网联汽车技术和产业体系全面建成、产业生态健全完善，整车智能化水平显著提升，高度自动驾驶的智能网联汽车大规模应用。2021 年，我国工业和信息化部发布了国家标准《汽车驾驶自动化分级》，如表1-1所示。当前自动驾驶技术的研发和落地主要在第 3 级（有条件自动驾驶）。

自动驾驶感知是自动驾驶系统中的最前端的模块，也是保障驾驶安全的最重要的一环。感知模块接收车载传感器收集的数据，筛选有用信息并生成感知结果，可比喻成智能车辆的“智慧眼”。自动驾驶感知任务按功能不同可分为以下两类：

（1）障碍物感知。针对车辆周围可能影响驾驶的动态物体和交通设施进行感知，遵循“检测-跟踪-预测”的三个步骤，即检测三维物体（目标）的位置、大小、角度、类别，根据时序信息跟踪物体得到物体的速度，最后根据物体的历史轨迹预测未来几秒的轨迹。除此之外，还需要识别物体的一些特殊属性，为后续规划提供风险程度的判断。

（2）环境感知。对周围环境中的行驶区域、车道线、交通标志、红绿灯等静态物体和区域进行检测和识别，为定位和规划模块提供信息。

自动驾驶感知常用的传感器包括彩色相机、激光雷达、毫米波雷达、红外传感器等，各个传感器成本不同，各有优劣，每个智能驾驶厂商都有其各自的解决方案。其中，“特斯拉”是纯视觉感知方案的代表，配备八个彩色相机，包括广角、长焦相机等，提供 360 度视野和最远 250 米的范围[3]。而大多数厂商使用多传感

表 1-1　驾驶自动化等级与划分要素的关系

| 分级 | 名称 | 持续的车辆横向或纵向控制 | 目标和事件探测与响应 | 动态驾驶任务后援 | 设计运行范围 |
|---|---|---|---|---|---|
| 0 级 | 应急辅助 | 驾驶员 | 驾驶员及系统 | 驾驶员 | 有限制 |
| 1 级 | 部分驾驶辅助 | 驾驶员及系统 | 驾驶员及系统 | 驾驶员 | 有限制 |
| 2 级 | 组合驾驶辅助 | 系统 | 驾驶员及系统 | 驾驶员 | 有限制 |
| 3 级 | 有条件自动驾驶 | 系统 | 系统 | 动态驾驶任务后援用户（执行接管后成为驾驶员） | 有限制 |
| 4 级 | 高度自动驾驶 | 系统 | 系统 | 系统 | 有限制 |
| 5 级 | 完全自动驾驶 | 系统 | 系统 | 系统 | 无限制* |

* 排除商业和法规因素等限制

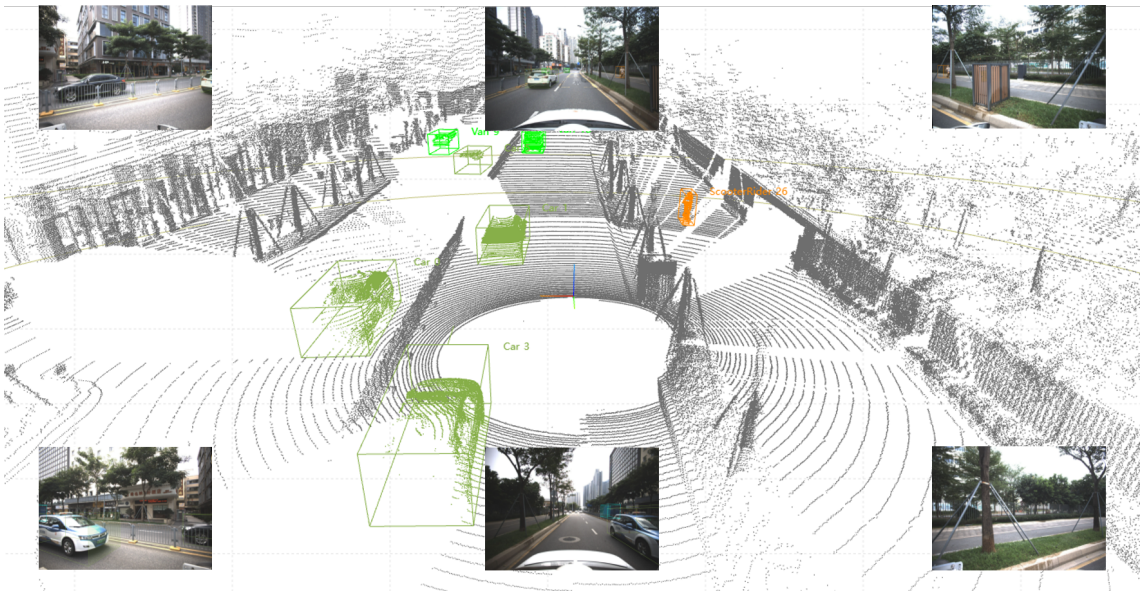



图 1-1　相机与激光雷达采集的驾驶场景数据样本

器融合的方案，通过多种传感器采集冗余的信息后进行更鲁棒的感知。常见的传感器配置是同时使用彩色相机与激光雷达。相机图像具备稠密的纹理信息和颜色信息，但缺失了深度信息，而激光雷达点云有着精确的深度信息但数据较为稀疏，如图1-1所示。场景地点为南方科技大学校园周边道路。其中图像采集自六个视角的彩色相机，视野覆盖360°，点云采集自顶部激光雷达。点云中的轿车、面包车、行人已被标注并高亮。图像和点云的信息可以互补，但由于（1）各自的数据性质和结构不同、（2）传感器的标定和同步存在难以避免的误差、（3）处理冗余的传感器数据将成倍增加计算时间，图像和点云的融合问题仍然是行业内的一大挑战。

随着图形处理器（Graphics Processing Unit，GPU）和相关硬件芯片的进步以及深度学习（Deep Learning，DL）算法的发展，自动驾驶的感知算法已不断走向成熟，各模块的神经网络模型架构已基本稳定，如今自动驾驶感知的研发已经进入数据驱动时代。对于当下数据驱动的自动驾驶研发模式，其面临的主要挑战是要解决数据的“长尾问题”，即自动驾驶算法模型需要不断地接收极端情况（corner cases）下的数据来进行迭代升级，以此增加模型的鲁棒性，使感知算法能成功应对复杂的路况、光照和天气条件等。因此，下一代自动驾驶感知技术的基础，是打通数据的采集-存储-清洗-标注和模型的第迭代-测试-部署的全自动或半自动化链路，如图1-2所示。其中，实现数据闭环的关键是自动化标注工具的开发。由于驾驶数据的庞大和人工成本的高昂，研究和开发一系列自动数据标注算法来节省人力并加速标注流程是是十分必要的。

基于上述背景，本文针对自动驾驶障碍物感知中的车辆与行人检测和跟踪算法进行深入的研究。通过研究基于深度学习的检测与跟踪架构、多模态传感器信息融合和离线跟踪优化算法提升在线与离线目标跟踪的准确率和计算速度，具有一定学术和工程价值。本研究旨在提升自动驾驶感知技术的创新性和准确性，加速实现数据闭环，以促进我国智能汽车的技术突破和工程落地，提高核心竞争力。

## 1.2　研究现状

目标检测（Object Detection）和多目标跟踪（Multi-Object Tracking，MOT）是计算机视觉领域的经典任务。目标检测是将同种类别的物体从背景中分离出来并回归出物体包围盒（目标框）的位置、大小和角度。多目标跟踪是在同种的多个物体中识别各自的身份，将同身份物体在连续时间内的位置串连形成轨迹。二维目标检测与跟踪在相机上的应用已十分成熟，如视频监控、无人机巡逻等，目前的三维点云的目标检测与跟踪算法大部分都是借鉴了二维图像的目标检测与跟踪的架构，但三维目标检测与跟踪在自动驾驶的应用中仍然存在以下技术挑战：

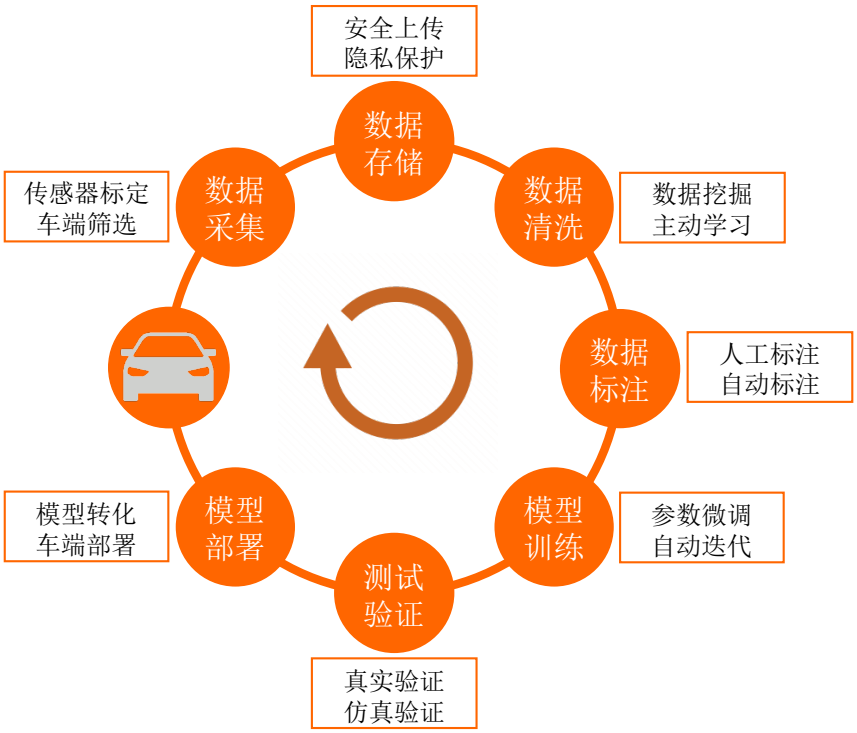



图 1-2　数据驱动下的自动驾驶模型开发链路与感知数据闭环

（1）**图像特征和点云特征的跨模态融合。**图像和激光点云在特征层面的融合可以有效提升感知网络的鲁棒性，同时进行时空特征的提取还可以有效解决目标的遮挡和数据稀疏等问题。目前行业在图像和点云融合特征提取网络仍处于探索阶段，相比于在网络层面使用更复杂的结构，在几何上寻找更有效的时空融合策略可能是更有价值的研究方向。

（2）**目标检测网络与多目标跟踪网络的合并。**目标检测与多目标跟踪在任务上有着一定程度的联系。目前主流的方法是将两个任务模型之间解耦，各自独立计算，但这会导致整体流水线的计算时间增加和上下文信息的丢失。由于目标在三维空间信息相比二维更具有区分能力，因此在对三维目标检测与跟踪网络的关联是十分必要的。

（3）**三维多目标跟踪算法的离线优化。**多目标跟踪的离线优化算法更偏向于工程应用，而目前在行业内公开的方法和开源工具非常少，大多数标注工具仍是基于简单的单目标跟踪算法或是在线多目标跟踪算法。目前针对自动驾驶数据集标注的离线三维多目标跟踪算法的研发是十分紧迫的。

针对以上挑战，本工作进行了大量文献调研，并在本章进行深入的问题分析与相关文献分析。1.2.1节介绍图像和点云单模态的特征提取网络，1.2.2节介绍图像的三维立体转化方法，1.2.3节介绍图像和点云的跨模态特征融合方法与时序融合方法，1.2.4节介绍三维目标检测架构，1.2.5节介绍在线多目标跟踪架构，1.2.6节

介绍离线三维目标的自动标注算法。

### 1.2.1　图像和点云的特征提取

对于图像处理相关的计算机视觉任务，卷积神经网络（Convolutional Neural Network，CNN）在特征提取的能力方面强于人工定义的特征描述子，并在各个公开数据集上成功证明其有效性。CNN 主要包括以下几个基本模块：（1）卷积模块；（2）归一化模块；（3）激活函数；（4）池化模块。将这些模块进行拼接和重复堆叠网络层，可以构建简单的深度学习模型，再通过反向传播优化算法和学习率的调控算法，即可进行模型训练。为了解决深度神经网络训练中的梯度消失和网络退化问题，ResNet[4]（残差网络）将卷积模块跨层连接，使得网络深度可以增加到 100 层以上，是图像识别领域的典型代表。在此之后，还有许多其他有效的特征提取网络被相继提出，同时也在目标检测和语义分割方面刷新记录。目前先进的特征提取网络有：Swin Transformer[5]（基于移动窗口的分层视觉 transformer）、ConvNeXt[6]（下一代卷积神经网络）等。这些特征提取网络都在大数据集上经过大量的实验支撑，拥有较为普适的参数结构和层级结构，适用于大多数下游任务。

表 1-2　点云和图像的数据结构的对比

| | 点云 | 图像 |
|---|---|---|
| 存储维度 | $[N \times (3+C)]$[a] | $[H \times W \times C]$[b] |
| 存储顺序 | 在 $N$ 维度上无序 | 有序 |
| 搜索复杂度 | $O(N)$[c]，无索引 | $O(1)$，有索引 |

[a] $N$ 表示数量，$3+C$ 表示点云的三维位置和其他特征如强度、伸长率等
[b] $H$、$W$、$C$ 分别表示图像的高度、宽度和通道数
[c] 大 O 符号，或称渐进符号

点云的数据结构和内在含义与图像不同，如表1-2所示，因此点云无法直接使用卷积进行特征提取操作。针对点云的特性，目前主流的特征提取方法根据特征构建方式可分为基于图（graph）的方法和基于栅格（grid）的方法两种。基于图的方法是根据原始点云的位置和点云之间的距离构建特征图，并使用特征聚类的方法对邻域特征进行深度编码，如 PointNet[7]、PointNet++[8]、DGCNN[9]是在点云分割方面的经典方法。基于栅格的方法则是将特定范围内的点云进行栅格化（体素化），根据三维体素（voxel）中的点云性质编码体素的初始特征，以此形成整齐有序的数据结构（可视为对二维图像的第三维拓展），然后对栅格进行特征提取操作。驾驶环境的三维空间普遍较大（前后左右的最大距离超过 50 米），因此需要设置较大的栅格体积来减少整体的分辨率和存储空间。在低分辨率的体素中尽

可能保留原始的点云信息是体素特征编码（Voxel Feature Encoding，VFE）的关键。VoxelNet[10]、PointPillars[11]等方法使用硬体素化（hard voxelization）的方式，即设置最大体素数量和每个体素内的固定点云数量进行体素的构建，对超过最大数量的体素和点云进行随机舍弃，对少于固定点云数量的体素进行补零操作。这种方法的构建过程简单，但会导致点云信息的丢失和冗余的数据存储。MVF[12]提出动态体素化（Dynamic Voxelization，DV），保留了所有原始信息并且没有冗余数据存储，但其长度不对齐的存储结构会导致后续点云特征融合在硬件上的计算时间增加，且自定义存储结构在工程部署上存在困难。而在构建体素之后，还需要对每个体素内的点云特征进行融合，即平均池化或者最大池化。最简单的方法是使用原始的点云特征（如强度信息等）[10,13]。除了传感器本身的特征外，还可以引入（1）点云关于体素的局部特征，如体素内各点到体素中心的位置偏移、体素内各点到体素点云的平均中心的位置偏移；以及（2）使用轻量的多层感知机（Multi-Layer Perceptron，MLP）网络进行逐点的特征编码[11]。

在三维体素的特征编码后，VoxelNet[10]对三维体素特征直接进行三维卷积操作。但是，由于三维卷积的计算量与体素的数量成正比，普通的三维卷积操作计算量会远远超过同尺度的二维卷积操作，因此目前先进的方法都避免对体素直接进行稠密的三维卷积，而是通过其他方式对三维体素进行降维，将三维栅格变为二维栅格后在鸟瞰图视角（Bird's Eye View，BEV）进行稠密的二维卷积。三维体素的降维主要有以下几种方式：（1）由于点云具有稀疏性，经过体素化后，大部分（大于 90%）的体素内部都是空的，因此只对非空的体素进行三维稀疏卷积即可大大减少计算量，经典方法如 SECOND[13]、流型稀疏卷积（Submanifold Sparse Convolution）[14]和焦点稀疏卷积（Focal Sparse Convolution，Focals Conv）[15]，通过稀疏卷积将体素特征的分辨率缩小后，使用高度压缩操作操作，将体素的高度维度合并至特征维度；（2）将体素设置为高度无穷大的柱子（pillar），提取稀疏体素特征后直接转成二维 BEV 特征图，经典方法如 PointPillars[11]；（3）使用 BEV 池化（BEV Pooling）操作，如 BEVFusion[16]、BEVDepth[17]；（4）其他卷积与求和操作，如 MDRNet[18]；

驾驶环境下采集点云数量庞大，可达到数十万的数量级，使用深度神经网络处理所有原始点云难以达到自动驾驶的实时性要求，因此基于图的方法往往需要对原始点云进行大幅度的随机降采样来减少计算量。由于神经网络的设置和硬件的要求，输入点云往往需要降采样至固定的数量，但传感器获取的点云数量会根据场景的变化而变化。降采样导致的信息丢失使得该类方法难以在室外大场景中应用。而基于栅格的方法通过定义体素来对点云降采样，虽然会增加内存消耗，但

有序的数据结构能大大减少邻域搜索的时间。在实际应用时需要对数据体量和数据精度之间进行权衡来设置体素的大小。此外，体素化后的三维稀疏卷积需要自定义算子，这在硬件上与经过优化后的传统卷积算子相比性能表现较差。因此，总体而言，在自动驾驶实际工程化应用中，由于苛刻的实时性要求和硬件要求，将点云体素化并降维至 BEV 后进行二维卷积的方法往往比基于图的方法和基于稀疏卷积的方法更加简易和快速。

### 1.2.2　图像特征的三维立体转化

通过三维点云投影至二维平面的方式可以直接得到点云与图像的对应关系，但将二维图像逆向投影至三维空间在数学上是一个病态问题（ill-posed problem）。图像信息从透视图（Perspective View，PV）转换到三维空间的方法，根据是否基于物理几何的先验可分为基于几何模型的方法和基于神经网络的方法[19]。利用物理几何的方法包括：（1）基于逆透视映射（Inverse Perspective Mapping，IPM）的方法，即通过假设像素点在同一水平面的约束来计算二维与三维的对应关系，如 BEVFeatStitch[20]、SHOT[21]等方法使用 IPM 作为后处理将检测与分割结果重构，而 Cam2BEV[22]、MVDet[23]、HomographyLoss[24]等方法则使用 IPM 将图像特征转换用于网络训练;（2）基于深度估计的方法，即通过估计像素点的深度将原始特征转换成新的三维空间表示并赋予特征，Pseudo-LiDAR[25]、Pseudo-LiDAR++[26]、AM3D[27]、PatchNet[28]、E2E Pseudo-LiDAR[29]等方法将图像转成伪点云，而 Lift-Splat-Shoot（LSS）[30]、BEVDet[31]、CaDDN[32]等方法则是估计像素点的深度分布并以此构建视锥。另一方面，使用神经网络的方法包括（1）基于 MLP 的方法，即使用 MLP 将 PV 特征直接映射成 BEV 特征，如 HDMapNet[33]、PVYA[34];（2）基于 transformer 的方法，即根据预先构造的三维查询，使用交叉注意力和位置编码搜索对应的 PV 图像特征，如 DETR3D[35]、PETR[36]、BEVFormer[37]、CMT[38]等。

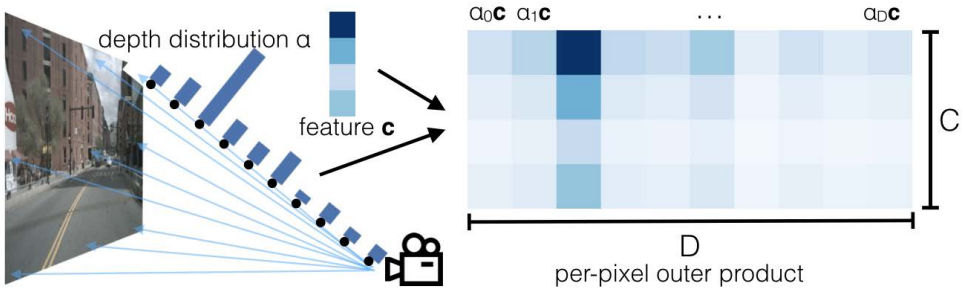



图 1-3　Lift-Splat-Shoot[30]方法中的“Lift”操作将二维图像特征转成三维栅格特征

在基于几何的方法中，基于 IPM 的方法有较强的可解释性，但无法将所有的图像特征映射到三维，且无法适用于非水平地面的场景。基于深度的方法明确地使用了某种三维的空间表示，如伪点云和三维栅格。早期方法大多使用伪点云，由

于其数据的复杂性导致这种特征表示难以与其他方法通用，特征提取和其他下游任务大多只能使用自定义的操作。最近的方法大多使用三维栅格，其生成的三维数据是有序的，在特征提取等其他操作上更加高效且有更强的通用性。在基于神经网络的方法中，基于 MLP 的方法是自底向上地将 PV 特征转换成 BEV 空间特征，基于 transformer 的方法是自顶向下地根据 BEV 空间表示搜索对应的图像特征。对比纯视觉感知任务的相关工作，基于 transformer 的方法在性能上强于基于 MLP 的方法，但在网络结构的复杂度和训练难度上要远大于基于几何的方法。

### 1.2.3　图像-点云的跨模态融合与时序融合

图像和点云包含这不同的语义信息，因此将两者的高层语义特征进行融合可增加感知的鲁棒性。根据图像和点云特征融合时使用的融合载体的不同，可将图像和点云的特征融合方法分以下三个类别：

（1）基于目标的融合方法。使用单模态中的候选或结果目标框作为融合载体，根据几何投影关系将目标级别的特征进行跨模态融合。MV3D[39]、AVOD[40]和 mmMOT[41]将三维目标框投影至图像平面上，提取二维投影框内的图像特征；F-PointNet[42]、F-ConvNet[43]、JRMOT[44]根据二维目标框在三维空间中生成视锥（frustum），提取三维目标视锥中的点云特征。TransFusion[45]将三维目标框投影至图像平面上生成高斯权重图，使用多头交叉注意力（Multi-Head Cross Attention）将权重图与图像特征融合。

（2）基于点云投影的融合方法。使用三维参考点作为融合载体，根据几何投影关系将图像语义信息赋给三维参考点，以此增强三维参考点的语义信息。Point-Painting[46]、FusionPainting[47]等方法将图像语义分割的分数与对应的点云输入进行融合。PointAugmenting[48]将图像的高维特征赋给对应点云输入。EPNet[49]和 EP-Net++[50]使用多尺度特征融合的方法，在点云特征提取网络 PointNet++ 的下采样和上采样层分别与图像特征提取网络的卷积层和反卷积层进行融合，并将结果赋给采样后的点云。3D-CVF[51]为图像和点云建立了不同稠密程度的三维栅格，将稠密的三维栅格根据中心点投影至图像并通过双线性插值获取图像信息，再压缩至 BEV 平面与点云的 BEV 特征进行融合。类似地，Focals Conv-F[15]在焦点稀疏卷积网络的中间层根据点云三维体素的中心点投影将图像分割网络的输出加入到体素特征中。

（3）基于图像逆投影的融合方法。使用1.2.2节中的图像三维转化方法将图像特征逆投影至三维体素中，再与点云构建的体素特征融合。BEVFusion[16,52]使用基于深度分布估计的 LSS[30]方法生成图像的 BEV 特征，与点云的 BEV 特征进行融合，如图1-4所示。CMT[38]使用 transformer 架构，将三维体素坐标编码后加入到

图像与点云的特征中，再将特征与目标查询向量在解码器中交互。

特征向量的融合方法包括直接叠加[46]、相加[15]、卷积[16,44]以及使用注意力机制[41,51-52]的动态融合，由于向量融合方法的性能与整体网络相关，解释性不强，对此本文不做深入探讨。

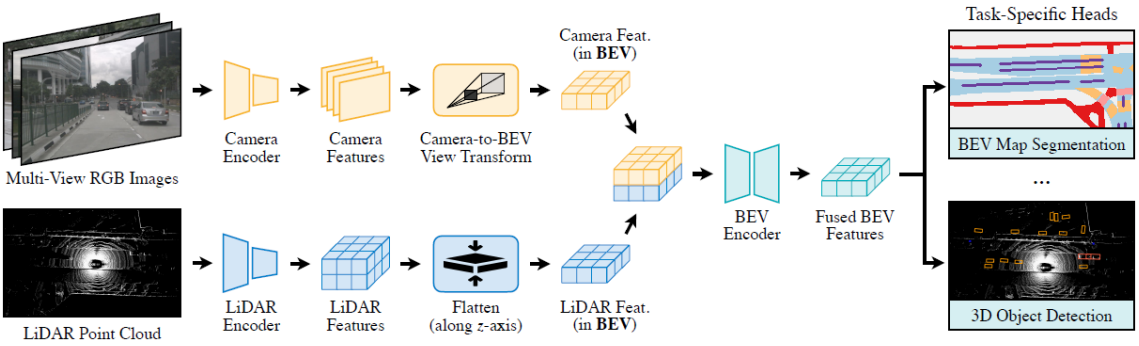



图 1-4　BEVFusion[16]方法将图像和点云的 BEV 栅格特征进行融合

实际应用场景中的传感器数据是连续时间的视频流和点云流，通过时序融合可以有效地提升数据的时空完整性。Mersch 等人[53]提出点云预测网络，将点云经过球面投影（Spherical Projection）生成二维距离图像（Range Image）后，将多帧距离图像在时间维度叠加，并使用三维卷积和反卷积操作对多帧距离图像进行编码和解码来预测未来多帧的距离图像。BEVDet4D[54]根据自车定位信息将历史的 BEV 特征图通过几何转换叠加到当前帧的 BEV 特征图上。BEVFormer[37]使用自注意力机制将当前 BEV 特征图与历史 BEV 特征图融合。

在图像和点云的特征融合方法中，目标级别的融合方法属于后融合，候选目标的生成受限于单模态特征的瓶颈；基于点云投影的融合方法由于点云的稀疏性，融合之后会导致图像信息的丢失，且传感器标定的误差会使融合的准确性会受到极大的影响；基于图像逆投影的融合方法使用了稠密的图像三维栅格进行融合，使得图像信息保留的更加充分，有序的数据结构也使得融合后的特征易于拓展，可以形成统一的特征图表示，用于多任务的学习。但这种稠密的图像特征表示也大大增加了内存的消耗，同时也对图像的三维立体转化能力有较高的要求。另一方面，在时序特征融合的方法中，虽然三维卷积十分高效，但距离图像的领域搜索与三维点云的邻域搜索存在差异，直接使用 PV 视角的卷积操作会降低特征的质量，而在 BEV 视角的时序融合将不存在这类问题。总体而言，基于图像逆投影并在 BEV 栅格图上进行图像和点云特征的融合，在融合的稠密程度和时序特征提取上具有优越性，但需要解决计算量、内存消耗以及三维转化准确度的问题。

### 1.2.4　三维目标检测架构

三维与二维的检测网络架构大体相近，都遵从统一的范式。目标检测网络的整体架构如图1-5所示，包含以下模块：（1）数据前处理，包括图像的标准化和大小调整、点云的体素化、图像-点云的对应矩阵计算等；（2）主干网络，负责多尺度数据的特征提取；（3）颈网络，负责聚合多尺度的主干特征；（4）头网络，负责特征到包围盒的预测，包括目标分类与包围盒的回归；（5）结果后处理，包括置信度过滤和非极大值抑制等。主干网络，即图像与点云的特征提取网络，包括图像特征的三维转化、多模态特征与时序特征的融合，已在1.2.1、1.2.2、1.2.3节中介绍，本节主要介绍颈网络与头网络在二维与三维目标检测的相关工作。

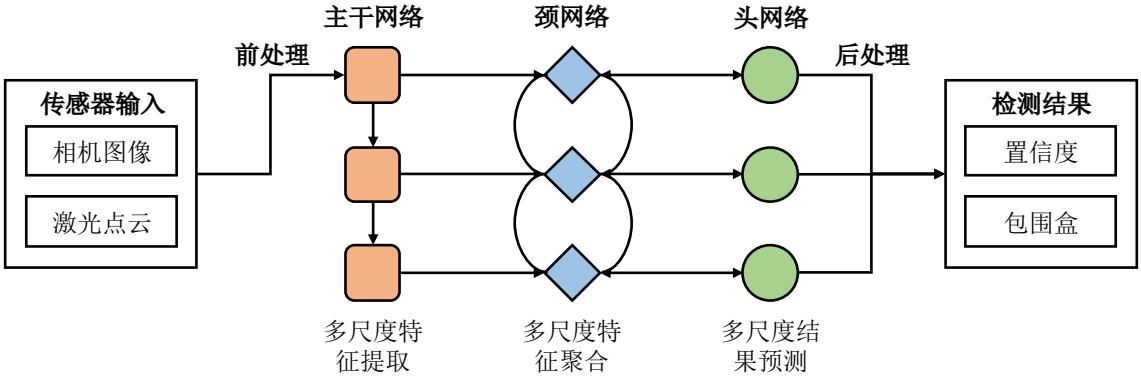



图 1-5　目标检测网络的一般架构

颈网络在目标检测架构中是一个可选的模块，它的提出是为了将多尺度的特征聚合以解决高层特征下采样后的信息丢失问题。在基于二维图像的颈网络中，特征金字塔网络（Feature Pyramid Network，FPN）[55]是一种典型的多尺度特征融合的网络结构，如图1-6所示，将特征图自顶向下地逐层进行上采样、卷积和相加操作。类似的颈网络结构还有 U-Net[56]，使用反卷积代替插值上采样，使用拼接加卷积代替相加。基于三维点云图的颈网络有不同的处理方式，PointNet++[42]使用集合抽象化（Set Abstraction，SA）和特征传播（Feature Propagation，FP）的方式进行点云特征的下采样卷积和上采样特征聚合。其中 FP 的基本思想是将采样源点的特征通过 K 邻近点（K-Nearest-Neighbor，KNN）插值，并将插值后的特征与目标特征叠加，再通过 MLP 降维。在三维目标检测网络中，基于体素的检测网络相比于基于点云图的检测网络有一个特别的优势，即三维体素可以几何降维至 BEV 平面后进行新一轮的特征提取。因此，基于体素的检测网络往往会在三维与 BEV 两个层面都设计主干网络和颈网络来提取特征，这也是三维目标检测网络与二维目标检测网络的显著差异之一。SECOND[13]、PointPillars[11]等基于体素的网络在 BEV 层面自定义了一种简单的颈网络结构 SECOND-FPN，即对多尺度特征分别使

用反卷积到同一尺度下后全部叠加起来。

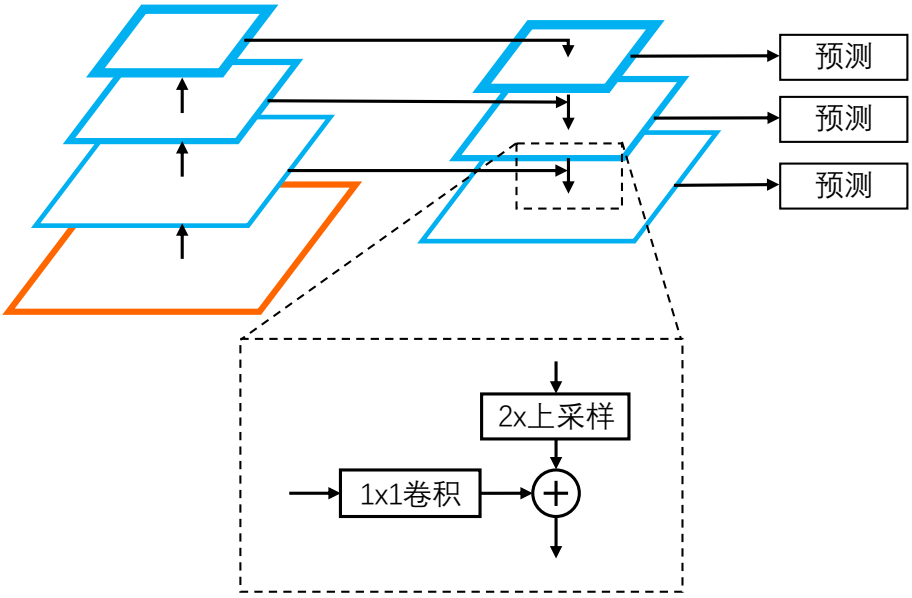



图 1-6　特征金字塔网络结构

头网络的输出与任务问题的定义相关，在目标检测中取决于使用的检测媒介和方法。目前主流的三维目标检测的头网络可分为：（1）基于锚点（anchor）的方法，即根据训练集中的目标大小作为先验，使用类似滑动窗口的方法让锚点在点云或栅格之间滑动，通过头网络判断锚点是否与真实目标重合，并输出置信度和锚点在大小、位置、角度上与真实目标之间的差异，许多经典方法如 VoxelNet[10]、SECOND[13]、PointRCNN[57]、PVRCNN[58]、VoxelRCNN[59]等都使用了锚点；（2）基于 BEV 高斯热力图的方法，即使用三维体素并降维至 BEV 后，在 BEV 上让网络输出目标的中心点热力图以及目标大小、位置、方位角等信息，经典方法如 CenterPoint[60]；（3）基于 transformer 的方法，即设计可学习的查询向量（动态锚点）和解码器，通过交叉注意力和自注意力机制输出固定数目的目标结果，目前这类方法大多数都是基于二维目标检测 DETR[61]方法的三维改版，如 DETR3D[35]、BEVFormer[37]等。虽然在整体思路上，三维检测方法都是借鉴了二维检测方法，但是由于三维物体有旋转角度且不存在近大远小的问题，如表1-3所示，三维目标检测头在细节上与二维目标检测头有一定差异。对于基于锚点的方法，三维检测只需要使用各类目标大小的平均值作为锚点即可，不需要使用不同尺度和横纵比的锚点。此外在输出的数据维度上，三维目标检测还要输出多一维度的目标位置和大小以及目标的方位角。

由于单阶段网络的输出结果有较多误差，许多方法还引入了第二阶段的基于区域的卷积神经网络（Region-based Convolutional Neural Network，R-CNN），通过提取候选目标的局部特征来进行更细致地分类和包围盒修正。二维目标检测中

表 1-3　二维与三维目标检测在回归任务上的对比

| 方法类别 | 二维目标检测 | 三维目标检测 |
| --- | --- | --- |
| 锚点 | 回归二维中心残差和二维大小残差，有多种尺度与横纵比，与目标类别无关 | 回归三维中心残差、三维大小残差和方位角残差（或其正余弦），不同目标类别的锚点大小不同 |
| 热力图、transformer | 回归二维中心和二维大小，与目标类别无关 | 回归三维中心、三维大小和方位角（或其正余弦），与目标类别无关 |

使用 R-CNN 的经典方法有 FasterRCNN[62]、MaskRCNN[63]、CascadeRCNN[64]等，一些基于点云的三维目标检测方法也借鉴了 R-CNN 的思路，如 PointRCNN[57]、PVRCNN[58]、VoxelRCNN[59]等。R-CNN 网络包含三个主要模块，（1）候选区域的局部特征提取、（2）感兴趣区域池化（Region-of-Interest Pooling，RoI Pooling）和（3）头网络。FasterRCNN 等二维目标检测方法直接扣取了第一阶段的特征图作为候选区域的特征，而 PointRCNN、PVRCNN、VoxelRCNN 等三维目标检测方法都对第一阶段特征进行了进一步处理，使用与包围盒区域相关的、更大分辨率的点云和体素特征。RoI Pooling 是指将候选区域的特征在大小上进行对齐，使得能够使用全连接网络进行分类和回归。在图像和点云上有着各自不同的对齐方法。总体而言，两阶段的三维目标检测网络对第一阶段网络的性能要求不高，因为在 R-CNN 阶段能有效提高检测精度，但第二阶段网络会大幅增加计算量，且操作较为复杂，不利于工程部署。

### 1.2.5　在线多目标跟踪架构

基于相机视频的二维多目标跟踪与基于激光点云的三维多目标跟踪有不同的难点，如表所示。目前大多数的多目标跟踪方法都是二维的，且大多是在行人跟踪数据集上训练和验证的。相机是静止的，行人的运动速度较低，而相机视频有较高的输入帧率，所以相邻帧的同一目标往往有较大的空间重叠。由于图像本身的性质，目标在图像上有极具差异的色彩信息和纹理信息，但目标的大小和速度会随着目标距离的变化而变化。而三维多目标跟踪则具有相反的特点。在驾驶场景中，自车是动态的，目标运动速度较高，而激光点云的帧率较低，所以相邻帧的同一目标位置变化较大；由于点云的稀疏性，同类别的目标点云不具有明显的外貌差异，但刚性物体的大小不会因距离的变化而发生变化。即使如此，目前的三维多目标跟踪方法大多还是借鉴了二维多目标跟踪的思路，都有着类似的框架结构。

多目标跟踪（MOT）算法的架构往往取决于对问题的定义。传统的视觉目标跟

表 1-4　二维图像与三维点云中的多目标跟踪的特点对比

| | 传感器帧率 | 目标外貌信息 | 目标位置变化 | 目标大小变化 | 目标重叠 |
|---|---|---|---|---|---|
| 基于二维图像的 MOT | 较大 | 丰富 | 较小 | 近大远小 | 是 |
| 基于三维点云的 MOT | 较小 | 稀疏 | 较大 | 与距离无关 | 否 |

踪算法是对模式图片与搜索图片进行相关计算，如使用均值漂移（Mean Shift）[65]、光流（Optical Flow）[66]、核相关滤波（Kernelized Correlation Filter，KCF）[67]、孪生网络（Siamese Network）[68]等。虽然这些方法已经有很成熟的理论研究，但这些先跟踪后检测的方法往往只适用于单目标跟踪（Single Object Tracking，SOT），没有考虑多目标之间的匹配矛盾和新目标出现的情况，本文将这类方法的范式定义为基于跟踪的检测（Detection-By-Tracking，DBT）。而当前主流的多目标跟踪算法为先检测后跟踪，即基于检测的跟踪（Tracking-By-Detection，TBD），以及检测与跟踪的并行，即联合的检测与跟踪（Joint Detection and Tracking，JDT）。多目标跟踪的架构如图1-7所示，包含以下模块：（1）目标检测网络，输出目标包围盒、类别和置信度；（2）目标相关网络，计算观测目标和历史轨迹间的互相关性，通常包括目标的外貌相似性和时空运动相似性两个方面；（3）数据关联，根据目标之间的相关程度建立匹配关系；（4）轨迹状态管理，管理轨迹的生命周期，包括轨迹的出生、命中、丢失和死亡。

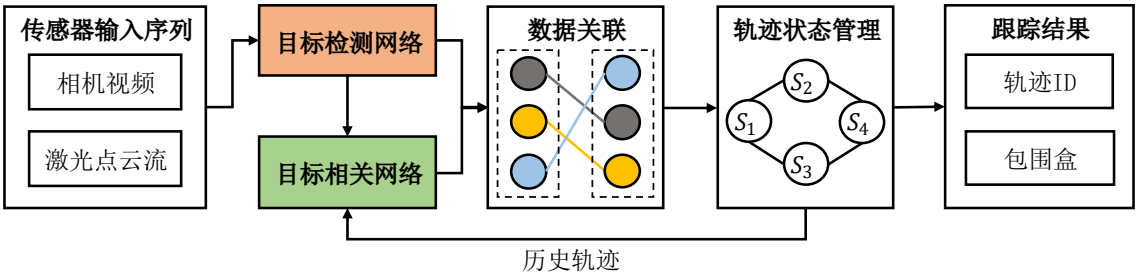



图 1-7　多目标跟踪算法的一般架构

基于 TBD 范式的 MOT 算法使用了分而治之（divide and conquer）的思想：将原问题拆分为目标检测、目标相关、数据关联等几个子问题，因此其最大的优势在于可以直接使用性能优越的的目标检测器和目标重识别网络（Re-identification，ReID）来达到较高的跟踪准确度。图像视觉领域的经典方法是简单的在线和实时跟踪（Simple Online and Realtime Tracking，SORT）[69]和在其基础上的利用深度关联度量的改进方法 DeepSORT[70]。这两种方法都使用了 FasterRCNN 的检测结果

作为输入，用基于恒定速度模型的卡尔曼滤波器（Kalman Filter，KF）对多目标的运动状态进行平滑估计和预测，并将预测结果与观测的目标进行互相关对比，之后利用相似性分数进行匈牙利匹配（Hungarian Algorithm，HA）输出数据关联结果。匈牙利算法的问题定义和解法将在2.4中详细介绍。在计算预测目标与观测目标的相似性上，SORT 使用了目标包围盒的交集除以并集（Intersection-over-Union，IoU），而 DeepSORT 同时使用了马氏距离（Mahalanobis distance）和目标 ReID 后的内嵌特征（embedding）的余弦距离，其中马氏距离仅作为阈值过滤，不参与匈牙利匹配的计算。AB3DMOT[71]将 SORT 推广到了三维空间。对于各种状态和置信度的目标和轨迹还可以采用多批次的匈牙利匹配，如 ByteTrack[72]。除了使用在线的卡尔曼滤波器外，还可以使用门控循环单元（Gated Recurrent Unit，GRU）[73]、长短期记忆（Long Short Term Memory，LSTM）[74]等神经网络的方法对目标的运动进行估计，如 Kim 等人的方法[75]和 Mono3DT[76]都使用了 LSTM 进行运动估计和多目标跟踪。由于 Tracking-by-detection 将检测模型与重识别模型、时序运动模型分开，导致整体流水线的计算时间增加，且模型之间没有交互，检测模型的精度变成整体算法性能的主要瓶颈。

近年来，一种新的联合的检测与跟踪（JDT）的范式被提出。JDT 包括以下两个方面：

（1）联合检测与重识别。此类方法只使用单帧数据输入，进行目标检测的同时进行个性化目标特征的提取，本质上属于多任务学习（Multi-Task Learning，MTL）。Voigtlaender 等人[77]提出多目标跟踪与分割（Multi-Object Tracking and Segmentation，MOTS）任务，其方法 TrackRCNN 在 MaskRCNN[63]的基础上引入时序三维卷积并在头网络上加入 ReID 分支提取 embedding。类似地，联合检测与内嵌网络（Joint Detection and Embedding，JDE）[78]基于 YOLOv3[79]加入 ReID 分支、FairMOT[80]论述了手工锚点在 JDE 架构中的缺点并基于 CenterNet[81]加入 ReID 分支。CSTrack[82]进一步论述了目标检测与 ReID 的竞争关系，提出使用自监督和多任务解码的机制将共享的 FPN 特征进一步分解成两部分后各自接入检测分支和 ReID 分支，同时在 ReID 分支引入空间注意力和通道注意力[83]对特征进行增强。除了改变输入输出与网络结构之外，多任务学习的损失函数往往还需要特殊的调整。Kendall 等人[84]联合了语义分割、实例分割和深度回归三个任务，提出使用可学习的不确定性参数作为各个分支的损失权重，JDE[78]和 FairMOT[80]也使用了这种方法联合了目标分类、目标框回归和 ReID 特征提取。以上都是基于图像视频的联合检测与重识别方法，目前在学术领域没有发现基于激光点云的联合目标检测与重识别上的方法和应用。

（2）联合检测与运动估计。此类方法需要多帧数据输入，进行目标检测的同时显式或隐式地进行了目标的运动估计。D&T[85]在 FasterRCNN[62]的基础上，将两帧的多尺度下的 RoI 特征做内积并与原特征叠加后进行回归，输出两帧的多尺度下的 RoI 的位移，在 RoI 特征内积时使用了邻域窗口进行限制，对相距较远的候选目标不进行互相关操作。Tracktor[86]使用前一帧的目标位置在当前帧进行目标分类。Chained-Tracker[87]使用连续两帧图像的输入，通过前景背景分类、相似性分类和成对目标回归同时生成两帧的目标。TubeTK[88]使用三维卷积提取时空特征并使用目标包围管道来代替目标包围盒直接生成轨迹。CenterTrack[89]使用两帧图像和前帧跟踪结果的目标置信度热力图作为输入，通过简单的卷积层升维后按位相加进行融合，基于 CenterNet[81]在目标检测头网络上加入运动分支，输出后帧的目标包围盒和与前帧目标相比的位移。为了避免测试时历史帧检测错误（包括漏检、多检和回归错误）导致出现网络没见过的输入，CenterTrack 还使用了相关的数据增强方法进行错误模拟。PermaTrack[90]使用 GRU 与卷积的合并操作 ConvGRU[91]将 CenterTrack 拓展到任意多帧输入，根据 GRU 的历史状态输出当前目标检测与位移结果，同时还输出被遮挡的目标。由于在实际场景的数据集中被遮挡的目标往往不被标注，PermaTrack 使用了仿真数据集和现实数据集联合训练。以上方法需要前后帧的目标有较大的重叠，因此只适用于目标运动较慢且视频帧率较高的场景中，不适用于运动速度较大、点云帧率较低的驾驶场景。另外还有部分方法在三维点云的目标检测网络的基础上进行运动估计。FaF[92]提出联合检测、跟踪和预测的多任务训练方式，使用类似 PointPillars[11]的单阶段目标检测架构，将高度压缩后的体素进行多帧时序叠加，使用三维卷积将时间维度减小至 1，最后进行当前帧的目标检测和未来多帧的目标位置预测。由于使用了简单的高度压缩和三维卷积，该方法达到了较高的运行速度（运行时间小于 30 毫秒），但是其检测精度和跟踪准确度不高。CenterPoint[60]在基于热力图的目标检测网络中加入速度回归网络。PC-TCNN[93]提出基于候选轨迹的两阶段目标检测与跟踪架构。首先在体素化特征提取的基础上，在 BEV 层面对多帧的二维栅格特征进行 ConvGRU 提取 BEV 时空特征；其次在 RPN 头网络上加入速度分支，并根据最后一帧的非极大值抑制（Non-Max Suppression，NMS）结果作为候选轨迹的种子，结合前帧的运动估计生成候选轨迹；最后基于 PointRCNN[57]的二阶段优化网络分别提取各帧的 RoI 特征，并使用 GRU 将属于同一轨迹的 RoI 特征时序融合，经过 R-CNN 头网络输出各帧优化后的目标包围盒。

JDT 还有基于 transformer 的特殊跟踪架构，这些方法大多数都是在 DETR[61]目标检测网络上的拓展。TransTrack[94]提出使用检测解码器和跟踪解码

器分别输出目标检测结果和前帧的预测结果，最后将检测结果和预测结果进行 IoU 匹配合并，其中跟踪解码器的查询输入是前帧的检测解码器的输出，训练时仅使用目标检测相关的损失函数。TrackFormer[95] 进行联合检测与重识别，如图1-8所示，只使用一种解码器，解码器的查询输入为前帧的过滤后的解码器输出，同时还输入时间窗口内未匹配的查询，解码器的输出为检测与重识别头网络的共同特征，训练时同时使用了目标检测和重识别的损失函数。MO3TR[96] 对查询向量进行了复杂的编码。首先对历史轨迹的状态进行时间注意力编码生成轨迹查询，然后与当前生成的目标查询一起进行空间注意力编码生成具有时空信息的查询，最后与图像主干网络特征一起输入到解码器。Ruppel 等人提出 TransMOT[97] 将 TrackFormer 应用到三维点云的多目标跟踪，该工作使用最远距离采样生成查询，同时还认为使用全局坐标系的点云输入会使得 transformer 的位置编码范围过大，因此使用激光雷达坐标系，并对前帧解码器的输出进行自车运动补偿后作为当前帧解码器的查询输入。

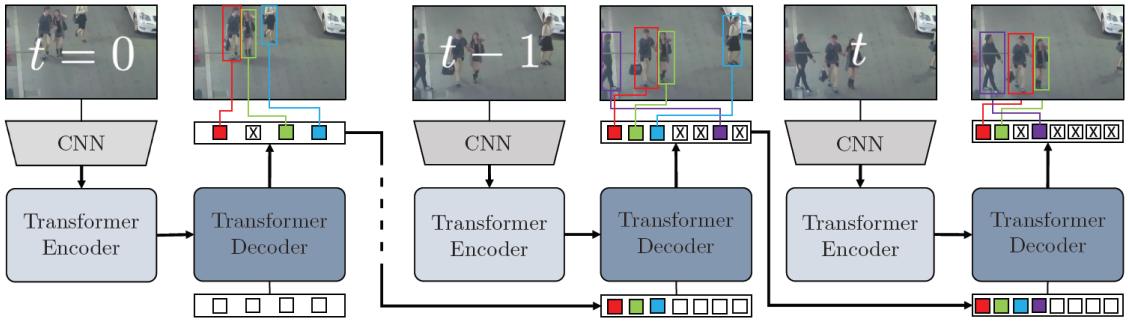



图 1-8　TrackFormer[95] 基于 DETR[61] 将历史的解码器输出作为当前的查询输入

总体而言，联合检测与重识别方法仅使用单帧输入，虽然有更高的拓展性，但由于时序信息缺失，网络模型容易对训练数据产生过拟合，所以往往需要在其他重识别数据集上进行训练。联合检测与运动估计的方法没有明显地对目标外貌个性进行监督。使用 transformer 的方法在目标和轨迹的查询上进行了复杂的全局交互，所以达到了更高的跟踪准确度。

### 1.2.6　离线三维目标自动标注算法

三维点云标注工具通常包含三个主要模块：数据预处理、数据可视化、人机交互操作，而自动标注算法应用于人机交互操作中，即利用离线算法生成初始标注结果，人工对部分结果进行审核和校正，再利用算法根据人工处理的结果对未处理的数据进行优化，并如此循环。当前公开的针对三维目标的点云标注工具通常采用一些具有泛化性的简单的几何算法来进行（1）目标包围盒的初始化和（2）跨帧的目标包围盒补全等。许多标注工具都是商业软件，无法得知其中的算法细

节，因此本节只介绍几个经典的开源标注工具使用的算法进行对比，并着重介绍在学术领域的离线多目标跟踪算法。

目前比较热门的针对三维动态目标的开源点云标注工具有：3D-BAT[98]、LATTE[99]、SUSTech POINTS[100]等。3D-BAT[98]在包围盒初始化方面没有使用几何算法进行辅助，在跨帧补全方面则使用了简单的线性插值。LATTE[99]在包围盒初始化方面使用了图像实例分割算法和点云聚类算法，其中图像实例分割算法是指将图像实例分割网络 MaskRCNN[63]的结果根据标定参数对应到点云上，以实现粗略的自动化点云分割。在人工标注阶段，首先使用迭代的方式进行地面去除，然后根据人工选择的目标初始点进行点云扣取和聚类，然后使用搜索算法估计包围盒。LATTE 在跨帧目标补全方面使用的是基于卡尔曼滤波器的单目标跟踪算法进行预测，之后人工对预测结果进行修正并更新目标状态。SUSTech POINTS[100]是本课题组开发的，在包围盒初始化方面使用的是方位角预测和包围盒搜索。具体流程为首先人工在 BEV 上选择一个初始目标区域，通过高度阈值去除地面点云，然后扣取区域内的点云使用神经网络预测目标的方位角，最后通过区域增长的搜索算法估计包围盒。在目标跨帧补全方面使用的也是基于卡尔曼滤波器的单目标跟踪算法，但与 LATTE 不同之处在于 SUSTech POINTS 在预测框的修正方面更加的自动化，使用了点云配准（registration）算法最小化两个点云的距离，自动地进行运动滤波器的更新。

目前开源的标注工具使用的都是半自动化的算法，它们更多地注重于可视化界面的美观性和操作的简易性上，整体标注流程的自动化程度不高且方法较为传统。具体而言，大多数的标注工具使用的是单目标跟踪算法或单目标的线性插值算法进行跨帧的预测和补全，这要求人工预先标注至少两帧以上同一 ID 的目标框。要实现真正的自动化标注，需要结合跨域的目标检测算法和离线多目标跟踪算法。本文不对跨域算法或弱监督算法进行介绍，只重点研究离线多目标跟踪算法。

离线算法对运行时间没有太大要求，且没有时序的限制，所以离线多目标跟踪算法往往只采用 TBD 的范式而不采用 JDT 的范式。本文将离线多目标跟踪分为两个阶段：

（1）对目标检测结果的 ID 分配的离线优化，即没有时序限制的目标数据关联。Zhang 等人[101]使用最小费用流实现全局数据关联，将所有帧的观测目标作为网络流的节点，将检测概率、跨帧连接概率、轨迹开始概率和退出概率作为边的花费，其中检测概率的花费可能为负值，其他的花费为正值，最终通过最小化目标函数即可实现全局的优化。类似地，Jerome 等人[102]使用 K-最短路径优化网络流，muSSP[103]使用了更高效的算法求解针对 MOT 的最小费用流问题。除了使

用网络流之外，Zhang 等人[104]提出使用层级聚类的方法将在线跟踪算法生成的短轨迹进行合并，具体而言就是设定一个轨迹相似性阈值，通过计算轨迹间的相似性自底向上循环地将轨迹进行合并，直到不再有轨迹的相似性大于阈值为止。AHC_ETE[105]则直接舍弃了在线跟踪，提出从头开始使用层级聚类合并离散目标。ReMOT[106]则是将在线跟踪生成的轨迹进行拆分，计算子轨迹间的相似性并使用层级聚类对轨迹进行重新合并。

（2）根据 ID 分配的结果对目标包围盒进行修正和补充。Offboard3D[107]先使用多帧融合的目标检测算法生成初始包围盒，然后使用简单的在线跟踪算法 AB3DMOT[71]生成跟踪结果，最后针对个跟踪结果进行轨迹的包围盒修正。根据包围盒在世界坐标系的运动，Offboard3D 将包围盒修正网络分为静态轨迹修正和动态轨迹修正两个分支：静态轨迹的修正网络与 PointRCNN[57]类似，在静态目标区域中使用基于点云分割的方法进行目标检测；而动态轨迹的修正网络则是对每一帧都进行目标检测，具体而言是将多帧目标点云和包围盒分别进行时序特征提取，并将两种特征拼接后进行当前帧的目标检测。Auto4D[108]使用现成的目标检测与跟踪算法生成初始轨迹，之后在 BEV 下对轨迹目标的大小和位置进行修正。其中轨迹目标大小的修正是将多帧目标点云拼接，进行 BEV 特征提取与目标大小的回归，对每条轨迹只回归一个固定的目标大小；而轨迹目标位置的修正是对每一帧都进行速度的回归，具体而言是将多帧目标点云拼接并记录点云的时间信息后，进行 BEV 特征提取，同时还对目标在当前帧 BEV 下的速度与角速度进行特征提取，最后将两种特征拼接后修正当前帧的速度与角速度。

在 ID 分配的离线优化方面，多帧全局优化与一帧一帧的在线优化相比其优点在于同时考虑多帧信息可以避免累计误差，但缺点在于只能利用观测目标的静态性质来计算相似性，无法进行多帧的运动估计，因为历史的关联结果未知。如最小费用流[101]中，目标跨帧连接的概率表示为大小、位置、外貌和时间四项，其中大小和位置对时间的条件概率是基于高斯分布估计的，这种估计在目标的运动速度较大时是十分不准确的，所以这种情况下跟踪的主要依据是外貌的相似性。然而，在三维多目标跟踪时，在 BEV 视角上不同目标的空间位置差异较大且不存在遮挡，因此运动估计应该是三维多目标跟踪不可或缺的一部分。层级聚类的方法考虑到了这一点，但整体的跟踪准确度完全取决于轨迹相似性的度量和停止轨迹合并的阈值。另一方面，层级聚类会在轨迹中间插入目标或轨迹，这导致更新轨迹后需要重新从头估计轨迹的运动，计算复杂度与空间复杂度较大，并且运动估计不准确。

在目标包围盒修正方面，目前的研究尚处于初期阶段。当前的方法都使用了

目标点云的时序拼接以及目标包围盒的运动性质作为输入，通过神经网络提取特征并融合，最后回归新的目标包围盒或目标运动性质。

## 1.3　本工作的主要内容与贡献

本文主要内容为研究自动驾驶障碍物感知中的三维目标检测与多目标跟踪技术。本文对二维和三维目标检测与跟踪算法进行了全面深入的调研，并主要在多目标跟踪的在线与离线算法方面进行了创新。本工作的主要内容与贡献如下：

（1）面向在线实时检测与跟踪应用，开发了一个基于相机和激光雷达输入的、能够同时生成三维包围盒和关联分数的端到端神经网络：JMODT。

（2）基于鲁棒的相似性度量设计，开发了一个基于多模态外貌特征和三维运动预测的目标相似性计算模块。

（3）基于观测不确定性和目标相关分数，开发了一个综合的跨帧数据关联模块。

（4）面向数据集自动标注应用，开发了一个可解耦的多模态离线三维多目标跟踪系统。

（5）基于点级别的投影映射和测试时间增强，开发了一个基于相机和激光雷达输入的感知结果集成模块。

（6）基于二维实例特征提取和卡尔曼滤波器，开发了一个鲁棒的正反双向多目标跟踪模块。

（7）基于轨迹聚类和贪心算法，开发了一个高效的正反轨迹融合模块。

（8）基于线性插值和轨迹预测，开发了一个准确的轨迹修正与补全模块。

（9）本工作在 KITTI 跟踪数据集[109]进行实验，本文提出的在线多目标跟踪算法在跟踪准确度和运行速度上都优于基准方法，本文提出的离线多目标算法在跟踪准确度上优于最新方法。在线方法的代码开源于：https://github.com/Kemo-Huang/JMODT

## 1.4　论文结构安排

本文分为五个章节，各章节的内容安排如下。

第一章介绍了自动驾驶三维目标感知的研究背景和意义，并深入的分析了三维目标检测与跟踪的技术难点并总结最新研究，包括图像和点云的特征提取方法、图像特征的三维立体转化方法、图像与点云的跨模态时序融合方法、三维目标检测方法、在线多目标跟踪方法以及离线三维目标自动标注方法。

第二章介绍了三维目标检测与多目标跟踪的基础理论与方法，并将理论和方法进行公式化的表达。

第三章提出了一种联合多目标检测与跟踪的在线跟踪方法：JMODT，详细介绍了在联合网络训练、目标相似性计算以及数据关联方面的方法创新，并分析了在公开数据集的实验结果。

第四章提出了一种离线多目标跟踪系统，详细介绍了在多模态感知结果集成、正反双向多目标跟踪以及轨迹融合与优化方面的方法创新，并分析了在公开数据集的实验结果。

第五章总结了全文，并对未来工作进行展望。

# 第 2 章　三维目标检测与多目标跟踪基础理论

## 2.1　引言

在面向自动驾驶的三维目标检测与多目标跟踪算法中，有一些基础的理论知识和广泛认同的方法，本工作时基于这些基础的理论和方法进行展开研究的。为了本文的可读性，本章将这些理论与方法进行介绍以及公式化的表达。

## 2.2　相机图像与激光点云的几何对应

为了融合相机图像特征与激光点云特征，各模态传感器之间需要进行标定（Calibration）。标定的参数包括针孔相机的内参矩阵与相机和激光雷达之间的外参矩阵。内参矩阵 $\boldsymbol{K}$ 是三维的相机坐标系 $\boldsymbol{P_c}$ 到二维的像素坐标系 $\boldsymbol{P_{uv}}$ 的投影矩阵，如公式(2-1)所示：

$$z_c\boldsymbol{P_{uv}} = z_c\begin{bmatrix}u\\v\\1\end{bmatrix} = \begin{bmatrix}f_x & 0 & c_x\\0 & f_y & c_y\\0 & 0 & 1\end{bmatrix}\begin{bmatrix}x_c\\y_c\\z_c\end{bmatrix} = \boldsymbol{K}\boldsymbol{P_c} \tag{2-1}$$

其中最左边的等号蕴含了齐次坐标变换，$(f_x, f_y)$ 是相机焦距（物理成像平面和光心的距离），$(c_x, c_y)$ 是光心到像素原点的平移，单位都是像素。外参矩阵 $\begin{bmatrix}\boldsymbol{R}_{3\times3} & \boldsymbol{t}_{3\times1}\end{bmatrix}$ 包括了相机坐标系 $\boldsymbol{P_c}$ 到激光雷达坐标系 $\boldsymbol{P_l} = (x_l, y_l, z_l)$ 的旋转 $\boldsymbol{R}$ 和平移 $\boldsymbol{t}$，如公式(2-2)所示：

$$\boldsymbol{P_c} = \begin{bmatrix}x_c\\y_c\\z_c\end{bmatrix} = \begin{bmatrix}\boldsymbol{R} & \boldsymbol{t}\end{bmatrix}\begin{bmatrix}x_l\\y_l\\z_l\\1\end{bmatrix} = \begin{bmatrix}\boldsymbol{R} & \boldsymbol{t}\end{bmatrix}\boldsymbol{P_l} \tag{2-2}$$

其中最右边的等号蕴含了齐次坐标变换。因此，相机图像与激光点云的整体几何对应关系可用公式(2-3)表示：

$$z_c\boldsymbol{P_{uv}} = \boldsymbol{K}\begin{bmatrix}\boldsymbol{R} & \boldsymbol{t}\end{bmatrix}\boldsymbol{P_l} \tag{2-3}$$

其中等号蕴含了齐次坐标变换。

在现实的传感器标定中，图像畸变、点云成像延迟、传感器时间同步等误差都会导致局部的数据由(2-3)得到的映射结果与实际结果不符。因此，在设计图像与

点云融合算法时，应该利用语义信息、扩大感受野等方法来尽可能弱化算法对传感器标定的依赖性。

## 2.3　卡尔曼滤波器的运动预测和更新

卡尔曼滤波器[110]是多目标跟踪的常用方法。该方法较为传统，已有多年的研究历史。三维多目标跟踪时需要对三维目标的空间状态进行估计、预测和更新，并将预测结果和观测结果进行相似性计算。具体而言，目标的三维运动状态 $\boldsymbol{s}$ 可以表示为 11 维的向量：

$$\boldsymbol{s} = \left(x, y, z, l, w, h, r, v_x, v_y, v_z, v_r\right) \tag{2-4}$$

其中 $(x, y, z)$ 表示目标包围盒的中心位置，$(l, w, h)$ 表示目标包围盒的长宽高，$r$ 表示目标包围盒的方位角，$(v_x, v_y, v_z)$ 表示目标包围盒在一帧时间 $\Delta t$ 内的位移，可视为目标的运动速度，$v_r$ 表示目标的角速度。

最简单且稳定的运动模型是以速度恒定假设（Constant Velocity Assumption，CVA）来设置目标运动状态的矩阵 $\boldsymbol{F}$。使用 CVA 的卡尔曼滤波器的过程模型可表示为：

$$\begin{aligned}
\hat{x}_{t+1} &= x_t + v_{x_t} + q_{x_t} \\
\hat{y}_{t+1} &= y_t + v_{y_t} + q_{y_t} \\
\hat{z}_{t+1} &= z_t + v_{z_t} + q_{z_t} \\
\hat{r}_{t+1} &= r_t + v_{z_t} + q_{r_t} \\
\hat{l}_{t+1} &= l_t + q_{l_t} \\
\hat{w}_{t+1} &= w_t + q_{w_t} \\
\hat{h}_{t+1} &= h_t + q_{h_t}
\end{aligned} \tag{2-5}$$

其中 $\hat{x}_{t+1}$ 表示在 $t+1$ 时刻对 $x$ 的预测；$q$ 表示过程噪声，服从均值为 0 协方差为 $\boldsymbol{Q}$ 的高斯分布。在 $t$ 时刻的目标状态 $\boldsymbol{s}_t$ 的平均估计为 $\boldsymbol{\mu}_t$，协方差为 $\boldsymbol{\Sigma}_t$，则在 $t+1$ 时刻，使用过程模型预测的目标状态 $\hat{\boldsymbol{s}}_{t+1}$ 的平均值和协方差为：

$$\begin{aligned}
\hat{\boldsymbol{\mu}}_{t+1} &= \boldsymbol{F}\boldsymbol{\mu}_t \\
\hat{\boldsymbol{\Sigma}}_{t+1} &= \boldsymbol{F}\boldsymbol{\Sigma}_t\boldsymbol{F}^T + \boldsymbol{Q}
\end{aligned} \tag{2-6}$$

通常情况下，使用 $\boldsymbol{o} = \begin{bmatrix} x & y & z & l & w & h & r \end{bmatrix}$ 作为观测输入，因此观测方程为 $\boldsymbol{H}_{7\times11} = \begin{bmatrix} \boldsymbol{I}_{7\times7} & \boldsymbol{0}_{7\times4} \end{bmatrix}$，其中 $\boldsymbol{I}$ 是单位矩阵。与过程模型一样，观测模型为线性模型，观测噪声服从均值为 0 协方差为 $\boldsymbol{R}$ 的高斯分布。因此，目标在观测空间下的

平均值和协方差在 $t+1$ 时刻的预测为：

$$\begin{aligned}\hat{\boldsymbol{o}}_{t+1} &= \boldsymbol{H}\hat{\boldsymbol{\mu}}_{t+1} \\ \boldsymbol{S}_{t+1} &= \boldsymbol{H}\hat{\boldsymbol{\Sigma}}_{t+1}\boldsymbol{H}^{T} + \boldsymbol{R}\end{aligned} \tag{2-7}$$

在三维多目标跟踪中，需要通过三维空间相似性度量计算每条轨迹的 $\hat{\boldsymbol{o}}_{t+1}$ 与每个实际观测结果 $o_{t+1}$ 之间的差异，作为目标运动相似性矩阵。在通过数据关联确定匹配关系之后，还需要根据对应的观测对轨迹状态进行更新。在 $t+1$ 时刻，目标状态的平均值和协方差更新为：

$$\begin{aligned}\boldsymbol{K}_{t+1} &= \hat{\boldsymbol{\Sigma}}_{t+1}\boldsymbol{H}^{T}\boldsymbol{S}_{t+1}^{-1} \\ \boldsymbol{\mu}_{t+1} &= \hat{\boldsymbol{\mu}}_{t+1} + \boldsymbol{K}_{k+1}\left(\boldsymbol{o}_{t+1} - \boldsymbol{H}\hat{\mu}_{t+1}\right) \\ \boldsymbol{\Sigma}_{t+1} &= \left(\boldsymbol{I} - \boldsymbol{K}_{t+1}\boldsymbol{H}\right)\hat{\boldsymbol{\Sigma}}_{t+1}\end{aligned} \tag{2-8}$$

其中 $\boldsymbol{K}$ 是卡尔曼增益。

## 2.4　指派问题与匈牙利算法

在线多目标跟踪算法中，跨帧的数据联合可以表示成当前观测与历史轨迹的指派问题，即一对一的二分图最大匹配，也可视为网络流问题的特殊形式。匹配的最终结果是节点数量少的一边全部被一对一地与另一边的节点匹配，且匹配后获得的分数最大，数量多的一边将有节点无法被匹配。

匈牙利算法（或 Kuhn-Munkres 算法）是一种针对二分图最大匹配问题（或最小花费问题）的快速解法，时间复杂度为 $O(|V|^3)$，其中 $V$ 表示二分图的顶点。二分图的匹配通常使用邻接矩阵来表达。匈牙利算法的基本思想是：对表示花费的邻接矩阵的一行或一列加上或减去一个数后，最优匹配结果不变。因此，只需要对邻接矩阵进行加减操作直至每一行或列都出现 0 为止，最终的匹配结果是在这些 0 中进行选择，保证只有一个 0 出现在一行和一列内。关于对此算法的最优性证明可参考原文[111]。

## 2.5　目标检测评价指标

目标检测的输出包括目标包围盒、目标类别和目标置信度。二维目标包围盒通常不包括旋转角，可用两种方法表示：（1）基于中心点的表示 $(x, y, w, h)$，其中 $(x, y)$ 表示中心点坐标，$w, h$ 表示矩形的宽和高；（2）基于顶点的表示 $(x_{min}, y_{min}, x_{max}, y_{max})$，其中 $(x_{min}, y_{min})$ 表示左上角顶点的坐标，$(x_{max}, y_{max})$ 表示右下角顶点的坐标。而三维目标包围盒通常使用基于中心点的表示方法 $(x, y, z, l, w, h, r_x, r_y, r_z)$，其中 $(x, y, z)$ 表示中心点坐标，$(l, w, h)$ 表示长方体的长

宽高，$(r_x, r_y, r_z)$ 表示三个轴对应的旋转角。目标检测中的基本评判要素包括真阳（True Positive，TP）、假阳（False Positive，FP）和假阴（False Negative，FN），即根据结果与地面真值（Ground Truth，GT）匹配后的相似性是否大于阈值来进行结果正确性的判断。二维目标检测的相似性度量通常直接使用 IoU，而三维目标检测由于引入了旋转角，三自由度的三维旋转 IoU 计算较为复杂，大部分的数据集和相关工作都将其简化为更容易计算的相似性度量，如一自由度的三维旋转 IoU[109,112]、BEV 旋转 IoU[109]、BEV 中心距离[113-114]、图像二维 IoU[109,114]等。

基于 TP、FP 和 FN，精度（precision）和召回率（recall）的计算如公式(2-9)和(2-10)所示：

$$\text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{2-9}$$

$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{2-10}$$

目标检测通常使用平均精度均值（mean Average Precision，mAP）作为评价指标。大多数情况下，mAP 是将全部目标类别的平均精度（Average Precision，AP）做平均后得到的，而 AP 是对根据不同置信度阈值产生的精度做平均得到的。平均精度在理论上应该是精度-召回率曲线（PR 曲线）的积分，但是实际上 PR 曲线的积分难以计算，所以通常使用在曲线上采样后近似计算面积的方法，即采样若干个置信度阈值进行计算。AP 的计算与置信度阈值的采样数量有关，数量越多，使用 AP 就越能表达检测结果的好坏。置信度阈值的设置通常使用 @ 符号进行表示，如 AP@11 则表示置信度阈值 $[0, 1]$ 区间等间隔采样 11 次。有些数据集（如 COCO[115]）的 mAP 计算是根据不同的 IoU 阈值得到的平均精度做平均，这种情况下每个类别都有一个 mAP。

## 2.6　多目标跟踪评价指标

多目标跟踪本质上是在目标检测之上的 ID 指派任务。在 TP、FP、FN 的基础上，MOT 针对 ID 的正确性判断还有更综合的评价指标：

（1）Li 等人[116]提出的基础度量，包括大部分跟踪（Mostly-Tracked，MT）、大部分丢失（Mostly Lost，ML）、部分跟踪（Partially Tracked，PT）、碎片（fragments）和身份交换（ID Switches，IDSW）。MT 表示 GT 轨迹被 TP 覆盖 80% 以上的百分比，ML 表示 GT 轨迹被 TP 覆盖 20% 以下的百分比，PT 表示 GT 轨迹被 TP 覆盖 20% 以上 80% 以下的百分比，即 $\text{PT} = 1 - \text{MT} - \text{ML}$，碎片表示 GT 轨迹与 TP 匹配后中断的次数，IDSW 表示同一预测 ID 的轨迹与 GT 匹配时 GT-ID 变化的次数。

（2）CLEAR MOT[117]度量，包括多目标跟踪精确度（Multi-Object Tracking

Precision, MOTP）和多目标跟踪准确度（Multi-Object Tracking Accuracy，MOTA）。MOTP 由公式(2-11)表示：

$$\mathrm{MOTP} = \frac{\sum_{TP} \mathcal{S}}{|\mathrm{TP}|} \tag{2-11}$$

其中 $\mathcal{S}$ 表示 TP 与 GT 匹配时的归一化相似性分数，如 IoU。MOTA 由公式(2-12)表示：

$$\mathrm{MOTA} = 1 - \frac{|\mathrm{FP}| + |\mathrm{FN}| + |\mathrm{IDSW}|}{|\mathrm{GT}|} \tag{2-12}$$

MOTA 被广泛用于数据集基准的主要评价指标，如 MOT Challenge 系列[118-119]。

（3）更高阶的跟踪准确度（Higher Order Tracking Accuracy，HOTA）[120]度量。HOTA 由真阳关联（True Positive Association，TPA）、假阳关联（False Positive Association，FPA）和假阴关联（False Negative Association，FNA）构成。对于某一个 TP 预测 $c$，TPA 的定义为：

$$\mathrm{TPA}(c) = \{k\}, k \in \{\mathrm{TP}|\mathrm{prID}(k) = \mathrm{prID}(c) \wedge \mathrm{gtID}(k) = \mathrm{gtID}(c)\} \tag{2-13}$$

其中 prID 表示预测的 ID，gtID 表示 GT 的 ID。TPA 可宏观理解为 $c$ 所属的预测轨迹中属于 $c$ 所属的 GT 轨迹的部分。FPA 的定义为：

$$\mathrm{FPA}(c) = \{k\}, k \in \{\mathrm{TP}|\mathrm{prID}(k) = \mathrm{prID}(c) \wedge \mathrm{gtID}(k) \neq \mathrm{gtID}(c)\} \cup \{\mathrm{FP}|\mathrm{prID}(k) = \mathrm{prID}(c)\} \tag{2-14}$$

FPA 可理解为 $c$ 所属的预测轨迹中不属于 $c$ 所属的 GT 轨迹的部分。FNA 的定义为：

$$\mathrm{FNA}(c) = \{k\}, k \in \{\mathrm{TP}|\mathrm{prID}(k) \neq \mathrm{prID}(c) \wedge \mathrm{gtID}(k) = \mathrm{gtID}(c)\} \cup \{\mathrm{FN}|\mathrm{gtID}(k) = \mathrm{gtID}(c)\} \tag{2-15}$$

FNA 可理解为 $c$ 所属的 GT 轨迹中不属于 $c$ 所属的预测轨迹的部分。最后，根据设定的 TP 判断阈值（如 IoU 阈值）$\alpha$，$\mathrm{HOTA}_\alpha$ 的定义为：

$$\mathrm{HOTA}_\alpha = \sqrt{\frac{\sum_{c \in \{\mathrm{TP}\}} \mathcal{A}(c)}{|\mathrm{TP}| + |\mathrm{FP}| + |\mathrm{FN}|}}, \tag{2-16}$$

$$\mathcal{A}(c) = \frac{|\mathrm{TPA}(c)|}{|\mathrm{TPA}(c)| + |\mathrm{FPA}(c)| + |\mathrm{FNA}(c)|} \tag{2-17}$$

$\mathrm{HOTA}_\alpha$ 也可分解为检测准确度（Detection Accuracy，DetA）和关联准确度（Association Accuracy，AssA），如以下公式所示：

$$\mathrm{DetA}_\alpha = \frac{|\mathrm{TP}|}{|\mathrm{TP}| + |\mathrm{FP}| + |\mathrm{FN}|} \tag{2-18}$$

$$\mathrm{AssA}_{\alpha} = \frac{1}{|\mathrm{TP}|}\sum_{c\in\{\mathrm{TP}\}}\mathcal{A}(c) \tag{2-19}$$

$$\mathrm{HOTA}_{\alpha} = \sqrt{\mathrm{DetA}\cdot\mathrm{AssA}} \tag{2-20}$$

最后，HOTA 是所有 $\alpha$ 采样后的 $\mathrm{HOTA}_{\alpha}$ 的平均，这与2.5节中基于不同 IoU 阈值的 mAP 计算类似。

总体而言，HOTA 评价指标更加显示地包含了检测准确度和关联准确度，比 MOTA 等指标更能评估算法的性能，但 MOTA 的计算更简单，普及率更广。

## 2.7　在线多目标跟踪的轨迹管理

在线多目标跟踪时，为了缓解目标检测的错误对轨迹结果的影响，通常会使用如图2-1所示的轨迹生命周期对轨迹进行管理。轨迹管理时，每条轨迹拥有四个状态：出生状态、跟踪状态、丢失状态和死亡状态；以及两个属性：命中次数 $n_{hit}$ 和丢失次数 $n_{miss}$。当某个历史轨迹被当前观测匹配时，增加该轨迹的命中次数并清除其丢失次数，反之则增加其丢失次数并清除其命中次数。目标状态的转移是根据目标的属性是否达到阈值决定的，阈值共有两种：命中阈值 $\theta_{hit}$ 和丢失阈值 $\theta_{miss}$。

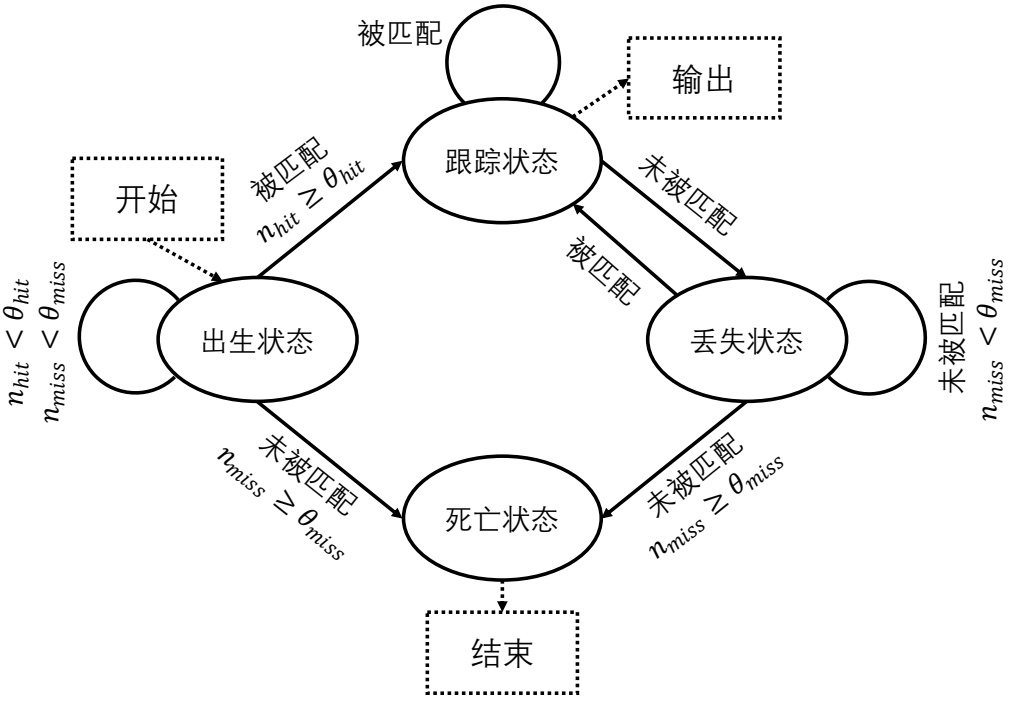



图 2-1　在线多目标跟踪轨迹管理的生命周期

具体的轨迹状态转移流程如下。在轨迹开始被观测时，处于出生状态。处于出生状态的轨迹可根据命中次数和丢失次数是否达到阈值而转移到跟踪状态或死

亡状态。只有处于跟踪状态的轨迹会被作为在线跟踪的结果被输出，处于死亡状态的轨迹会被删除，处于其他状态的轨迹会保留在内存中但不作为在线跟踪的结果。上一时刻处于跟踪状态的轨迹，若在当前时刻没有被匹配则会转移到丢失状态，否则继续留在跟踪状态并被输出。处于丢失状态的轨迹一旦被重新匹配则转移回跟踪状态，否则留在丢失状态，若丢失次数超过丢失阈值则转移到死亡状态。

在大多数的多目标跟踪方法中，通过以上流程的轨迹管理，可以有效地减少对 FP 观测的输出，轨迹丢失时也可以在一段时间内保留轨迹等待重新被匹配，即减少 FN 观测对 ID 交换的影响。

# 第 3 章　联合三维多目标检测与跟踪：JMODT

## 3.1　引言

在自动驾驶障碍物感知和数据集标注的研究中，多目标跟踪是一个极其重要的任务。由于相机提供了高分辨率的彩色信息和纹理信息，激光雷达提供了高精度的三维信息，许多自动驾驶相关的目标检测与跟踪的解决方案更倾向于使用相机与激光雷达融合的策略。通常情况下，传感器融合的性能会受到传感器标定的质量的影响。相比于单目标跟踪，多目标跟踪的准确度在目标数量很多的时候会更容易受到目标遮挡的影响。虽然过去已有不少基于相机与激光雷达融合的多目标跟踪算法的研究，但目前仍存在以下三个主要的技术难点：

（1）**联合三维目标检测与跟踪**。大多数的三维目标检测与多目标跟踪算法是基于 tracking-by-detection 范式的，即串联地进行目标检测、目标相关和数据关联，这种流水线会导致计算冗余，且模型之间没有交互，容易生成次优解，最终导致检测模型的精度变成整体算法性能的最大瓶颈。使用一种联合的三维目标检测与跟踪框架进行并行的目标相关计算更适合实时应用。

（2）**鲁棒的相似性计算**。目标的特征的和相似性度量的质量会对数据关联的结果有重大的影响。一个鲁棒的相似性度量应该包含目标的外貌和运动信息来解决跟踪过程中出现的细微目标外貌差异、复杂的运动轨迹和稠密的目标数量分布问题。

（3）**综合的数据关联**。影响跟踪结果的因素还包括许多不确定性，如检测错误、目标遮挡、重识别错误、目标出现与离开。因此，在数据关联优化时需要将这些因素全面、综合地进行考虑。

当前的多目标跟踪算法可以归为两类：（1）基于 tracking-by-detection 范式的方法和（2）联合检测与跟踪的方法。前者将目标检测与目标相关模型（重识别或运动估计）分开隔离训练互不干扰，并且串联地进行推理。这样的框架有可能陷入局部最优并且将消耗额外的硬件计算和内存资源。后者则在目标检测与相关的网络中共享了部分的目标特征。但由于任务和数据集的差异，能够使用的多任务学习的数据集相对匮乏，训练这样一个更大的网络会更加困难。许多的相似性估计方法都基于（1）重识别（ReID）特征和（2）运动预测来提高跟踪的稳定性。但是，由于缺乏深度信息，二维图像中的目标特征和运动信息会严重地受到目标遮挡的重叠的影响，尤其是在目标数量较多的情况下。大多数在线数据关联方法只考

虑了目标间的相似性来进行最大二分图匹配，而目标检测的置信度仅仅只用于前处理的目标过滤和非极大值抑制。针对上述三个技术难点，本章提出一个实时且鲁棒的联合多目标检测与跟踪（Joint Multi-Object Detection and Tracking，JMODT）系统来进行三维目标检测与各种的联合学习、鲁棒的相似性计算和综合的数据关联。本工作的主要贡献如下：

（1）面向在线实时检测与跟踪应用，开发了一个基于相机和激光雷达观测输入的并能够同时生成三维包围盒和关联分数的端到端神经网络。

（2）通过鲁棒的相似性度量设计，开发了一个同时基于多模态外貌特征和三维运动预测的目标相似性计算模块。

（3）通过同时考虑观测不确定性和目标相关分数，开发了一个综合的数据关联模块。

（4）在 KITTI 跟踪数据集[109]的实验结果表明，本方法的跟踪性能在跟踪准确度和运行速度上都优于基准方法。本方法的代码开源于：https://github.com/Kemo-Huang/JMODT

## 3.2　系统架构

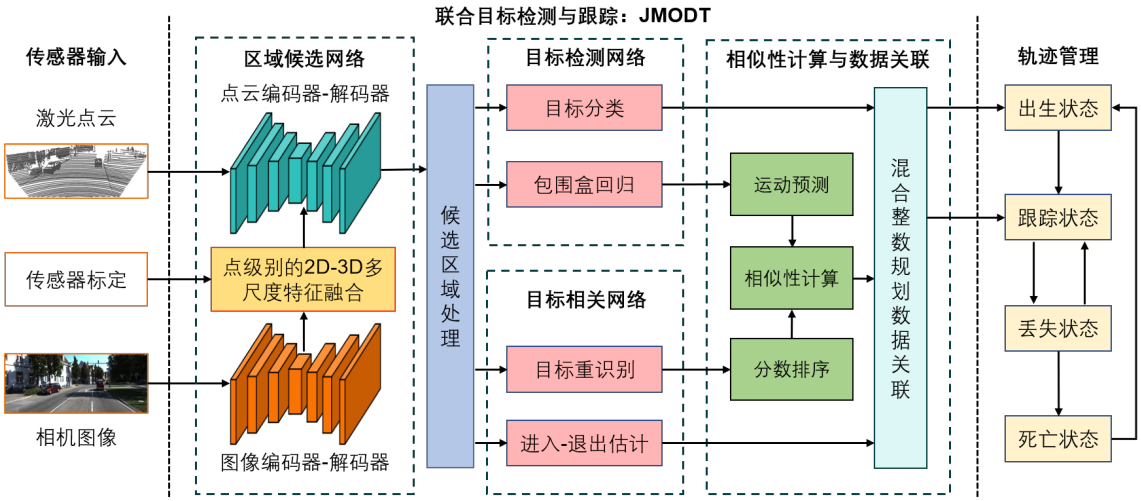



图 3-1　联合多目标检测与跟踪的系统架构图

JMODT 系统如图3-1所示包含五大主要模块：（1）区域候选网络（RPN）、（2）并行的检测与相关网络、（3）相似性计算模块、（4）数据关联模块和（5）轨迹管理模块。整体的跟踪过程包含五个阶段：（1）经过传感器标定后的相机图像与激光雷达输入 RPN 生成感兴趣区域（RoI）以及对应的多模态 RoI 特征，（2）根据 RoI 及其特征，并行的检测与相关网络进行区域特征提取，生成改进后的检测结果、ReID 相似性和进入-退出的概率，（3）根据运动预测和分数排序机制进一步

优化 ReID 相似性，（4）使用混合整数规划（Mixed-Integer Programming，MIP）的方法将检测结果和优化后的相似性进行综合的数据关联，（5）将数据关联结果进一步管理来解决目标遮挡的再现的问题并生成连续的目标轨迹。整体上，JMODT 是基于相机与激光雷达融合的两阶段三维目标检测框架 EPNet[49] 之上的拓展。

### 3.2.1　三维目标检测网络：EPNet

EPNet 的是一个基于图像与点云特征融合的两阶段三维目标检测网络，网络分为两个部分：（1）区域候选网络（RPN）。RPN 由主干网络、颈网络和头网络构成，本质上是点云分割网络与包围盒回归网络的结合。其中主干网络与颈网络负责传感器数据的特征提取，头网络负责生成目标包围盒和其置信度，RPN 整体流程如算法3-1所示。（2）区域修正网络（R-CNN）。R-CNN 由区域点云池化、标准化区域特征提取网络和区域头网络构成，本质上是点云分类网络与包围盒回归网络的结合。

#### 3.2.1.1　点云特征提取网络与图像特征提取网络

点云特征提取网络为 PointNet++[8]，它是一种基于图（graph）的点云特征提取架构，在进行点云分割时，包含下采样编码和上采样解码两个阶段，流程与目标检测相同，可视为目标检测中的主干网络和颈网络。给定无序的激光雷达点云，PointNet++ 特征提取流程分为以下阶段：

（1）随机采样。将点的数量采样至固定数量 $N$ 后，作为神经网络的输入。由于实际点云的密度与深度有关，即深度越大，点云越稀疏，本工作使用的采样策略为保留深度为 40 米以上的点云，对近处的点云进行采样。若近处的点云较多则进行随机下采样，所近处点云较少则进行随机重复采样。

（2）建图。根据点云的三维空间位置，计算各点之间的欧式距离，建立索引和图。

（3）集合抽象化（Set Abstraction，SA）。首先使用最远距离采样（Farthest Point Sampling，FPS）策略进行关键点采样，选定点云中的关键点；其次，根据给定的最大球半径和邻点数量查询关键点周围的点云进行聚类；最后，对每个点云簇内的点云特征使用 MLP 进行升维后进行最大池化生成具有邻域信息的关键点特征。PointNet++ 使用多个 SA 模块，即多个下采样网络层，来对点云进行多尺度的特征编码。

（4）特征传播（Feature Propagation，FP）。FP 模块对各 SA 层的多尺度特征进行向上聚合。给定下层关键点的特征，首先使用 K 邻近点策略，在上层点云中查询关键点周围点云进行聚类；然后在每个点云簇中，使用临近点与关键点的距

算法 3-1　EPNet 中的 RPN 整体流程

**输入:** 当前帧的图像 $M_{img}$，矩阵大小为 $H \times W \times C_{img}$，点云 $M_{pc}$，矩阵大小为 $N \times (3 + C_{pc})$，传感器标定参数 $(\boldsymbol{K}, \boldsymbol{R}, \boldsymbol{t})$，锚点 $A$，置信度阈值 $\theta$

**输出:** 三维目标候选区域 $O_{box}$、类别 $O_{category}$) 和置信度 $O_{score}$

/* 图像预处理 */

$M_{img} = \text{norm}(M_{img})$ ; // 图像归一化

$M_{img} = \text{pad}(M_{img})$ ; // 填补图像右下角至固定大小 $H' \times W'$

/* 点云预处理 */

$M_{proj} = \text{proj}(M_{pc}, \boldsymbol{K}, \boldsymbol{R}, \boldsymbol{t})$ ; // 使用公式(2-3)计算点云到图像的投影坐标

$(M_{pc}, M_{2D}) = \text{filter}(M_{pc}, M_{proj}, H, W)$ // 过滤在图像视锥外的点云

$M_{pc} = \text{sample}(M_{pc}, N')$ ; // 根据深度对点云进行随机采样至固定数量 $N'$

$G_{pc} = \text{graph}(M_{pc})$ ; // 计算点之间的欧式距离并建立索引

/* 初始化层级特征数组 */

$A_{img_conv} = \text{array}(5)$ ; // 图像下采样特征数组

$A_{pc} = \text{array}(5)$ ; // 点云特征数组

$A_{img_deconv} = \text{array}(4)$ ; // 图像上采样特征数组

$A_{img_conv}[1] = M_{img}$;

$A_{pc}[1] = M_{pc}$;

/* 多尺度特征提取和融合 */

**for** $i = 1$ **to** 4 **do**

  $A_{img_conv}[i+1] = \text{Conv}[i](A_{img_conv}[i])$ ; // 图像下采样编码

  $A_{img_deconv}[i] = \text{Deconv}[i](A_{img_conv}[i+1])$ ; // 图像上采样编码

  $A_{pc}[i+1] = \text{SA}[i](A_{pc}[i], G_{pc})$ ; // 点云下采样编码

  $F_{img4pc} = \text{interp}(A_{img_conv}[i+1], A_{pc}[i+1], M_{proj})$ ; // 双线性插值

  $A_{pc}[i+1] = \text{fusion}(F_{img4pc}, A_{pc}[i+1])$ ; // 点级别特征融合

**end**

**for** $i = 4$ **to** 1 **do**

  $A_{pc}[i] = \text{FP}[i](A_{pc}[i+1], A_{pc}[i])$ ; // 点云上采样编码

**end**

$F_{img_concat} = \text{concat}(A_{img_deconv})$ ; // 图像特征叠加

$F_{img4pc} = \text{interp}(F_{img_concat}, A_{pc}[1], M_{proj})$ ; // 双线性插值

$F_{final} = \text{fusion}(F_{img4pc}, A_{pc}[1])$ ; // 点级别特征融合

/* 头网络预测 */

$S_{pc} = \boldsymbol{\sigma} \cdot \text{class_head}(F_{final})$ ; // 点云分割

$R_{pc} = \text{reg_head}(F_{final})$ ; // 点云回归

/* 候选区域生成和后处理 */

$(S_{fg}, R_{fg}) = \text{filter}(S_{pc}, R_{pc}, \theta)$ ; // 前景置信度过滤

$(O_{score}, O_{category}) = \max(S_{fg})$ ; // One-hot 解码

$O_{box} = \text{decode}(R_{fg}, A)$ ; // 锚点解码

$(O_{box}, O_{category}, O_{score}) = \text{nms}(O_{box}, O_{category}, O_{score})$ ; // 非极大值抑制

**return** $(O_{box}, O_{category}, O_{score})$

离的倒数作为线性插值的权重，将关键点的特征传播给邻近点；最后，对于上层的每个邻近点，将传播来的关键点特征与原始特征拼接，使用 MLP 进行特征聚合。FP 模块与 SA 模块一一对应，最终顶层的点云包含各尺度的特征信息。

图像特征提取网络与 U-Net[56] 架构类似，即使用二维卷积与反卷积操作，分层进行特征下采样编码和上采样聚合。为了维持点云特征和图像特征在尺度上的相似性，图像特征下采样层数与 PointNet++ 的下采样层数保持一致。

#### 3.2.1.2　图像-点云特征融合

EPNet 在特征提取阶段使用点级别的特征融合，根据公式(2-3)得到点云在图像上的投影坐标，使用双线性插值进行栅格采样获取对应的图像特征。受到通道注意力和空间注意力[83]的启发，EPNet 通过对图像特征和点云特征使用 MLP 进行降维和相加操作，将两个模态的特征转化成权重向量后与图像特征相乘，然后将加权后的图像特征与点云特征进行拼接和降维，得到经过动态融合的多模态特征，如图3-2所示。“+”和“×”分别表示元素级别的相加和相乘，$\boldsymbol{\sigma}$ 表示 sigmoid 函数，C 表示拼接。

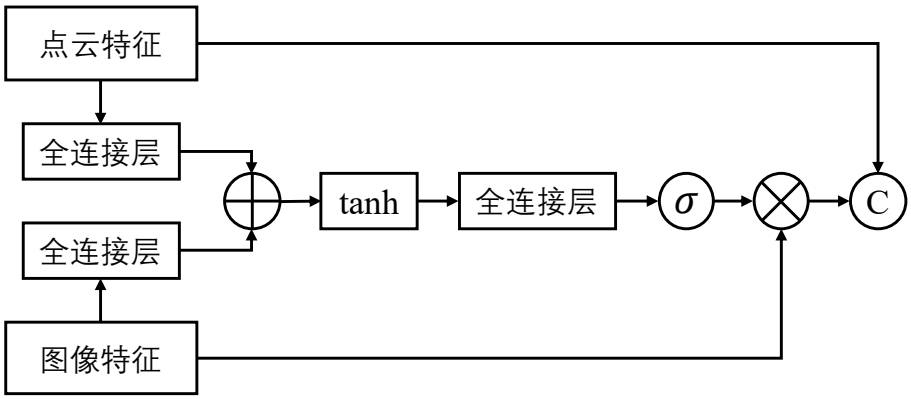



图 3-2　EPNet 中点级别的图像-点云特征动态融合

#### 3.2.1.3　基于锚点 RPN 的头网络和损失函数

PointNet++[8] 的原文描述的是一个点云分割的网络，而在此基础上加入一个回归目标包围盒的 MLP 分支即可作为目标检测网络，分类与回归在特征输入和前一部分的 MLP 网络层上可以共享。三维锚点是人工设定大小的三维包围盒，实际实验使用的一般是训练数据集中所有同类别目标的大小平均值。基于锚点的三维目标检测头需要回归出前景目标的三维中心残差、三维大小残差和方位角残差（或其正余弦）。基于图像的 RPN 中，如 FasterRCNN[62]，只是进行前景与背景的二分类，锚点与目标类别无关，对于目标类别的判断是在第二阶段 R-CNN 中进行的。基于点云的 RPN 则不同，三维目标大小不会因深度而改变，因此对不同目标类别

可分别只设置一个锚点。由于不同类别的锚点不用，三维 RPN 在进行点云分割的时候就需要进行目标类别的判断，且不同类别的目标可以共享一个回归网络。在完成头网络的分类和回归后，还需要进行置信度阈值的过滤、目标区域包围盒的解码以及非极大值抑制。训练时，对于目标分类使用的损失函数为焦点损失（focal loss）[121]

#### 3.2.1.4　基于区域点云特征提取的 R-CNN

EPNet 使用了与 PointRCNN[57] 相同的 R-CNN 架构来提取区域特征和改进候选包围盒。首先在原始点云中搜索属于候选包围盒内部的点，获取其对应的 RPN 颈网络提取的特征。为了增加一些原生点的结构信息，将候选包围盒内的点的三维坐标转换到目标坐标系，输入 MLP 进行升维进行位置编码。将位置特征拼接到 RPN 特征上，再用 MLP 降维。二阶段的 R-CNN 网络中的分类分支可看成是点云分类任务，即将候选区域内的点云作为一个整体进行二分类，生成候选区域是否为真实目标的概率。除了分类分支之外，还有进一步的回归分支，这与 RPN 的回归分支类似，只是将锚点替换成了候选区域，回归结果是真实目标与候选区域的位置、大小和方位角的偏差。

### 3.2.2　问题描述

基于上述的系统架构，本章提出的方法专注于解决以下三个问题：

（1）如何基于共享候选区域特征正确地训练平行的目标检测和目标相关网络？

（2）如何基于运动预测结果和 ReID 分数鲁棒地计算目标相似性？

（3）如何基于目标的分类置信度、相似性和进入-退出概率实现综合的数据关联？

## 3.3　本章提出的方法

### 3.3.1　平行的目标检测与相关

为了实现目标检测与目标相关的并行，共享的候选区域特征需要进一步的处理。在不改变 RPN 中的候选区域生成和 R-CNN 的局部特征编码模块的前提下，本工作为目标相关网络增加了两个特征预处理步骤：候选区域特征的筛选和相关操作，如图3-3所示。另外，在网络推理的过程中，将 RPN 生成的候选区域特征进行了保存来避免重复的计算。

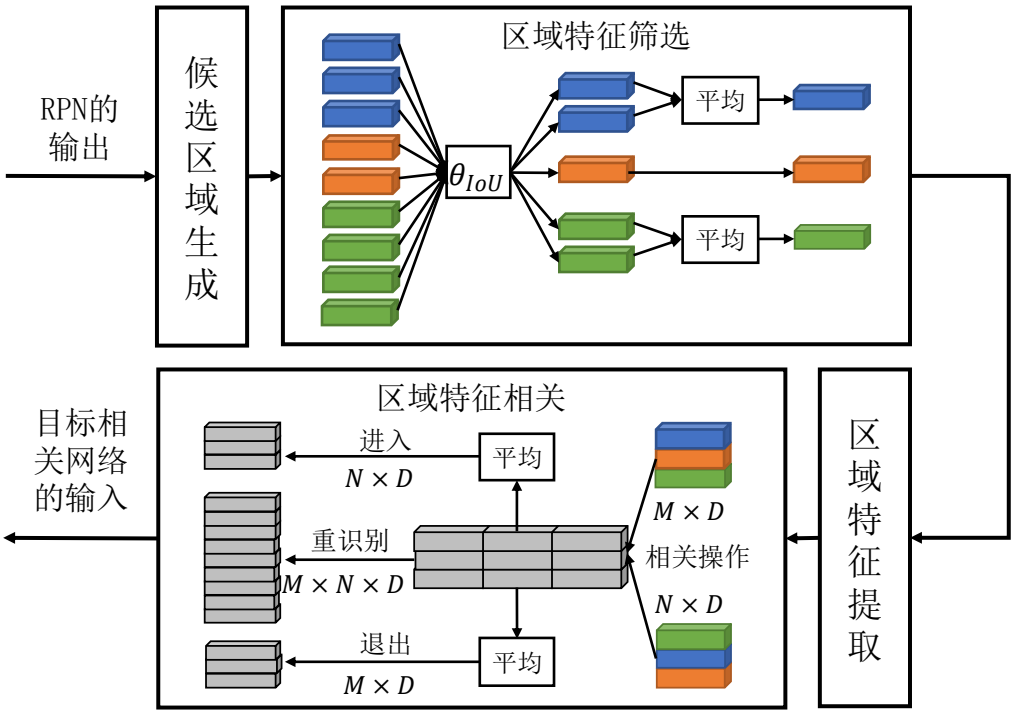



图 3-3　候选区域特征的筛选和相关操作

### 3.3.1.1　区域特征筛选

许多通过 RPN 生成的前景的候选区域只有较低的与真实标签的重合程度（IoU≈60%），因为它们是用来训练 R-CNN 网络使其有能力对不准确的目标包围盒进行回归校准。然而，这些粗略的候选区域不能直接用于识别任务，因为这些区域包含的目标信息不全，区域的重叠也会导致信息混淆。为了解决上述问题，在相关网络的训练时，本工作提出两个操作来帮助候选区域和真实目标的对齐：

- 为输入的候选区域设置一个较高 IoU 阈值 $\theta_{iou}$；
- 计算属于同一个目标 ID 的候选区域特征的平均值。

总体而言，前者通过过滤无用的特征输入来帮助网络训练的收敛，后者通过平衡使用共同特征和缺失特征来提高候选区域特征的质量。另一方面，在网络推理时，还需要设置一个较高的分类置信度阈值 $\theta_{cls}$ 来过滤候选区域。这是因为在区域特征筛选后，相关网络的训练缺少对负样本候选区域的监督。实验过程中，通过经验设置了 $\theta_{iou}$=$\theta_{cls}$=0.85。

### 3.3.1.2　区域特征相关

在进行 ReID 分数和进入-退出概率的学习之前，本工作使用绝对差[41]（相减后取绝对值）作为两个候选区域特征之间的相关操作，以此来表示跨帧目标间的依赖性。在 $t$ 帧给定 $M$ 个筛选后的区域特征，在 $t+1$ 帧给定 $N$ 个筛选后的区域特

征，则相关后的特征矩阵大小为 $M \times N$。一对多的全局特征相关性可将这个 $M \times N$ 的相关特征矩阵沿行和列进行平均。由于目标进入-退出的估计是一个对称的任务，这些生成的 $N$ 个“进入”特征和 $M$ 个“退出”特征可以直接被批量化送入一个共同的进入-退出网络分支。

#### 3.3.1.3　目标相关网络的组成和损失函数

目标相关网络中的 ReID 分支和进入-退出分支都是基础的 MLP。每个被筛选的候选区域特征可以被分配一个独特的 ID 标签，每个特征对都会被分配一个关于 ID 匹配的二分类标签。因此，ReID 和进入-退出的概率估计都可视为一种二分类任务。本工作分别使用 SoftMax 排序和 Sigmoid 函数来将 ReID 和进入-退出网络的输出映射到 $[0, 1]$ 区间，并使用二元交叉熵损失来训练网络。

### 3.3.2　目标相似性计算

目标对之间的相似性（affinity 或 similarity）计算应该同时考虑目标的外貌和运动信息。目标外貌相似性是对3.3.1节中介绍的目标相关网的络输出进行 SoftMax 排序后的结果；目标运动相似性是通过2.3节介绍的卡尔曼滤波器进行运动预测后，对观测目标与预测目标在几何上的相似性计算的结果。给定 $M$ 个轨迹预测和 $N$ 个目标观测，目标相似性可表示为 $\boldsymbol{A}_{M\times N} = \{a_{1,1}, a_{1,2}, \cdots, a_{M,N}\}$。

此前的经典工作 DeepSORT[70] 同时应用了目标位置的马氏距离（Mahalanobis distance）和目标 ReID 特征的余弦距离，将两者加权求和作为最终匹配分数。其中马氏距离是欧式距离与预测目标的状态协方差矩阵的结合，因此不确定性更高的预测目标计算出的距离更大。但是，由于无法对特征描述子的余弦距离归一化，也无法对状态的马氏距离归一化，使得最终加权求和时难以平衡两者的权重。最终，DeepSORT 将马氏距离的匹配权重设置为 0，将马氏距离仅用于阈值过滤，而主要使用 ReID 特征进行匹配。

本工作改进了上述相似性度量方法。在运动相似性方面，受到二维目标检测中的损失函数 Distance-IoU Loss[122] 的启发，本研究提出三维的 Distance-IoU 相似性 $\boldsymbol{A}^{DIoU} = \boldsymbol{A}^{dis} + \boldsymbol{A}^{IoU}$ 来度量观测与预测的运动相似性：

$$\forall i, \forall j, a_{i,j}^{DIoU} = a_{i,j}^{dis} + a_{i,j}^{IoU} = \left(1 - \frac{\rho(b_i, b_j)}{d}\right) + \frac{B_i \cap B_j}{B_i \cup B_j} \tag{3-1}$$

其中 $B$ 表示目标的三维包围盒，$b$ 表示 $B$ 的中心点，$\rho$ 表示欧式距离，$d$ 表示两个三维包围盒最远的顶点距离，如图3-4所示。前一项的距离相似性 $a_{i,j}^{dis} = 1 - \frac{\rho(b_i, b_j)}{d}$ 是为了帮助补充后一项的 IoU 相似性 $a_{i,j}^{IoU} = \frac{B_i \cap B_j}{B_i \cup B_j}$，尤其是在两个包围盒没有重叠（$a_{i,j}^{IoU} = 0$）的情况下，使用本研究提出的空间相似性度量仍能提供有效信息。

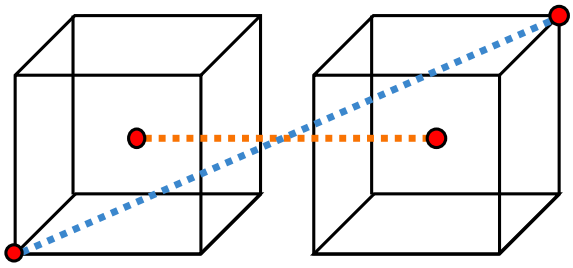


图 3-4　三维目标包围盒的归一化距离计算

与此同时，归一化后的距离与外貌相似性属于同一尺度，两者能够进行加权。因此，最终的目标匹配分数 $\boldsymbol{X}^{link}$ 是目标外貌相似性 $\boldsymbol{A}^{ReID}$ 和目标运动相似性 $\boldsymbol{A}^{DIoU}$ 的加权和：

$$\boldsymbol{X}^{link} = \alpha \boldsymbol{A}^{ReID} + \beta \boldsymbol{A}^{DIoU} \tag{3-2}$$

其中 $\alpha$ 和 $\beta$ 是权重超参数。

### 3.3.3　基于 0-1 混合整数规划的数据关联

类似于最小费用流问题[101]，本研究将 MOT 的数据关联问题定义为寻找以下四种 0-1 变量的最优解：

$$\boldsymbol{Y} = \left[\boldsymbol{y}^{cls} \quad \boldsymbol{y}^{link} \quad \boldsymbol{y}^{entry} \quad \boldsymbol{y}^{exit}\right], \boldsymbol{y} = \{y_i\}, y_i \in \{0,1\} \tag{3-3}$$

其中 $\boldsymbol{y}^{cls}$ 表示目标是否被分类为真，$\boldsymbol{y}^{link}$ 表示观测的目标与通过轨迹预测的目标是否匹配为同一 ID，$\boldsymbol{y}^{entry}$ 表示观测目标是否临时进入，$\boldsymbol{y}^{exit}$ 表示轨迹目标是否临时退出，可以将进入和退出理解为是否不应被其他任何目标匹配）。它们对应的四种置信度分数为：

$$\boldsymbol{X} = \left[\boldsymbol{x}^{cls} \quad \boldsymbol{x}^{link} \quad \boldsymbol{x}^{entry} \quad \boldsymbol{x}^{exit}\right], \boldsymbol{x} = \{x_i\}, 0 \leqslant x_i \leqslant 1 \tag{3-4}$$

其中 $\boldsymbol{x}^{cls}$ 表示目标检测的置信度，$\boldsymbol{x}^{link}$ 表示通过公式(3-2)计算的相似性分数，$\boldsymbol{x}^{entry}$ 和 $\boldsymbol{x}^{exit}$ 表示进入-退出网络输出的进入-退出置信度。对于当前时刻 $t$，给定 $M$ 个轨迹和 $N$ 个目标观测，0-1 变量之间的约束为：

$$\begin{aligned} \forall i, y_i^{cls} &= \sum_{j=1}^{N} y_{i,j}^{link} + y_i^{exit} \\ \forall j, y_j^{cls} &= \sum_{i=1}^{M} y_{i,j}^{link} + y_j^{entry} \end{aligned} \tag{3-5}$$

由于进入和退出的对称的，本文将进入-退出的 0-1 变量统一表示为 $\boldsymbol{y}^{ee}$、置信度表示为 $\boldsymbol{x}^{ee}$。本工作提出的目标函数为：

$$\arg\max_{y}\left[w^{cls}\left(\boldsymbol{x}^{cls}-1\right)\boldsymbol{y}^{cls}+w^{link}\boldsymbol{x}^{link}\boldsymbol{y}^{link}+w^{ee}\boldsymbol{x}^{ee}\boldsymbol{y}^{ee}\right] \tag{3-6}$$

其中 $(w^{cls},w^{link},w^{ee})$ 为权重超参数。相比于之前的相关工作[41,123]直接使用 $\boldsymbol{x}^{cls}$ 作为系数，本工作选择将 $\boldsymbol{y}^{cls}$ 对应的系数设为负值 $(\boldsymbol{x}^{cls}-1)\in[-1,0]$，因为目标检测的不确定性应该作为一个惩罚项来避免目标被匹配或为假阳观测生成新的轨迹，换言之，当目标 $i$ 的检测置信度低时，$y_i^{cls}$ 应该更倾向于为 0。不同于最小费用流的工作[101]中提出的目标函数：

$$\arg\min_{y}\left[\log\frac{1-\boldsymbol{x}^{cls}}{\boldsymbol{x}^{cls}}\boldsymbol{y}^{cls}-\log\boldsymbol{x}^{link}\boldsymbol{y}^{link}-\log\boldsymbol{x}^{ee}\boldsymbol{y}^{ee}\right] \tag{3-7}$$

本工作选择通过设定额外的超参数来调整目标函数中三项的权重。在网络训练时并没有对各分支输出进行相互的约束，只是将值域控制在 0 到 1，不平衡的分数比例会导致最终优化结果也失衡，通过超参数的调节可以生成更长的轨迹和更少的假阳性输出。根据构建的 0-1 混合整数规划问题，本工作使用通用的混合整数规划计算工具 OR-Tools[124]进行求解。

## 3.4　实验验证

### 3.4.1　数据集

本工作使用了 KITTI 目标跟踪数据集[109]作为方法的验证平台进行车辆（car）的多目标跟踪。该数据集提供了前视角相机图像和 64 线的顶部激光雷达点云数据，相机图像与激光点云的数据已被同步为 10 Hz。数据包含 21 个训练序列和 29 个测试序列，其中数据的训练序列被分为训练集和验证集，两者有着大致相等的帧数量，而测试序列没有标签，需要生成结果后上传官方服务器进行评估。目标的标注为三维目标包围盒、目标类别和身份 ID。KITTI 在整体的评价上使用了2.6节中介绍的 MOTA、HOTA 等指标进行跟踪结果准确性的判断。此外，本工作还加入了每帧的运行时间（Run-Time per frame，RT）作为额外的速度评价指标。

虽然 KITTI 的目标标注为点云下的三维包围盒，但 KITTI 目标跟踪基准（benchmark）在 TP、FP、FN 上的判断是基于二维图像平面的，即将三维包围盒的 8 个顶点投影至图像后，将能够包围该 8 个顶点的最小的二维包围盒作为目标对象，判断预测目标与 GT 目标的二维 IoU 是否大于阈值 0.5。这不同于其他主流的自动驾驶数据集（如 nuscenes[113]和 Waymo[112]）在 BEV 平面上进行评价，因此二维目标检测与跟踪结果也可以进行评价测试。但根据三维包围盒投影的二维包围

盒会比正常的二维标注偏大，且包含了目标被遮挡的部分，这也使 KITTI 与其他主流的二维 MOT 数据集（如 MOT Challenge 系列[118-119]）不同。因此，KITTI 目标跟踪数据集在评价指标层面上，既不算三维 MOT 也不算正常的二维 MOT，这是该数据集的缺点之一。此外，KITTI 的城市场景中的大多数车辆都是静态的（相对路面静止），因此根据自车的定位数据将传感器数据映射到全局坐标系下会使跟踪较为容易。KITTI 虽然提供了 GPS/IMU 的定位数据，但可视化后发现其定位的误差较大难以使用，无法使用全局坐标系进行目标检测和跟踪也属于该数据集的缺点。尽管如此，该数据集由于提供了高质量的多模态数据、传感器标定较为准确等优点被广泛用于早期的自动驾驶感知方法验证。

### 3.4.2　具体实现

本方法中的深度神经网络是基于 PyTorch[125]实现的。本工作使用了 EP-Net[49]官方在 KITTI 目标检测数据集上预训练的检测模型，并将目标相关网络在 NVIDIA TITAN V 上训练了 50 个周期（epochs），训练时使用的批大小（batch size）为 12，优化器为 AdamW[126]，学习率调度器为余弦退火，初始学习率为 2e-4。本工作根据在验证集的最优结果的超参数进行配置，在相似性计算时，设置 $\beta = 10\alpha$，在数据关联时设置 $w^{cls} = 100, w^{link} = 22, w^{se} = 1$，这些超参数都与模型输出的比例相关。本工作使用的目标检测模型输出的置信度普遍较高（不确定性较小），因此需要较大的检测不确定性权重。根据经验，设置较大的 $w^{cls}$ 可以突出目标检测的不确定性在数据关联时的作用，设置较小的 $w^{se}$ 可以减少轨迹中断的次数。在如图2-1所示的轨迹管理时，本方法舍弃了轨迹出生的缓冲处理，即设置目标变为跟踪状态所需要的被命中的最短时长为 $\theta_{hit} = 0$，因为检测结果的不确定性已经在混合整数规划中考虑了。此外，本方法设置轨迹变为死亡状态所需要的最大丢失时长为 $\theta_{miss} = 2$，这样能为数据关联保留更多的轨迹输入防止目标丢失。对于数据关联结果中的假阳性目标（$y^{cls} = 0$），本工作保留它们为临时轨迹并初始化它们的丢失帧数为 $t_{miss} = 1$。最终，只在线输出 $t_{miss} = 0$ 的目标观测结果。

### 3.4.3　消融实验

本研究依次将外貌相似性、IoU 相似性和距离相似性移除来验证他们的相似性度量的作用。从表3-1中可以看出，同时使用三种度量可以显著提高跟踪的准确度，而移除某种相似性度量则会使性能下降。另外，从使用单模态相似性度量进行跟踪的准确度可以看出，在三维空间中目标的运动相似性比外貌相似性要更加准确。

此外，为了评估目标检测的不确定性对数据关联过程的影响，本研究使用匈

| 相似性度量 | FP↓ | FN↓ | IDSW↓ | MOTA↑(%) |
|---|---|---|---|---|
| 外貌 | **520** | 1098 | 659 | 79.51 |
| IoU | 532 | 1067 | 52 | 85.14 |
| 距离 | 637 | **954** | 5 | 85.64 |
| 外貌 +IoU | 556 | 1033 | 6 | 85.65 |
| 外貌 + 距离 | 534 | 1037 | 4 | 85.82 |
| IoU+ 距离 | 588 | 987 | 4 | 85.79 |
| 外貌 +IoU+ 距离 | 578 | 975 | **2** | **86.01** |

表 3-1　使用不同相似性度量的跟踪性能对比

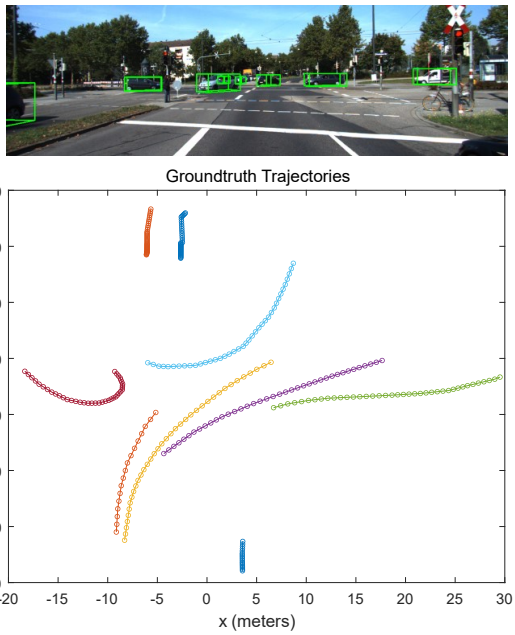
牙利算法作为基线的数据关联方法进行对比。匈牙利算法假设了所有的观测输入都是真值，即不确定性为 0，并进行尽力匹配。表3-2显示使用三种不同质量的观测输入的对比实验结果，检测置信度阈值 $\theta_{cls}$ 越高代表输入的质量越高，实验时使用的相似性权重相同。可以看出本章提出的联合检测不确定性、目标相似性和目标进入-退出概率三种因素的数据关联方法要远优于匈牙利匹配算法。其主要原因在于匈牙利匹配算法无法处理假阳性输入（FP），且其尽力匹配的机制使大量的 FP 直接导致匹配错误，因此也出现了大量的 ID 交换。而本方法通过使用检测不确定性和进入-退出概率可以显著地减少 FP 和 ID 交换。

| 置信度阈值 $\theta_{cls}$ | 数据关联方法 | FP↓ | FN↓ | IDSW↓ | MOTA↑(%) |
|---|---|---|---|---|---|
| 0.85 | 匈牙利算法 | 1946 | **834** | 1169 | 64.47 |
| | 本方法 | 578 | 975 | 2 | **86.01** |
| 0.90 | 匈牙利算法 | 1781 | 881 | 1170 | 65.52 |
| | 本方法 | 561 | 1000 | **1** | 85.94 |
| 0.95 | 匈牙利算法 | 1466 | 1008 | 1087 | 87.96 |
| | 本方法 | **483** | 1101 | 3 | 85.72 |

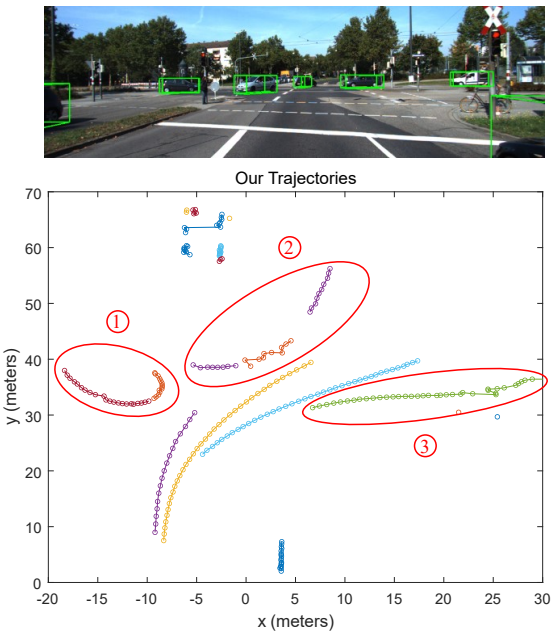
表 3-2　使用不同数据关联方法的跟踪性能对比

### 3.4.4　案例分析

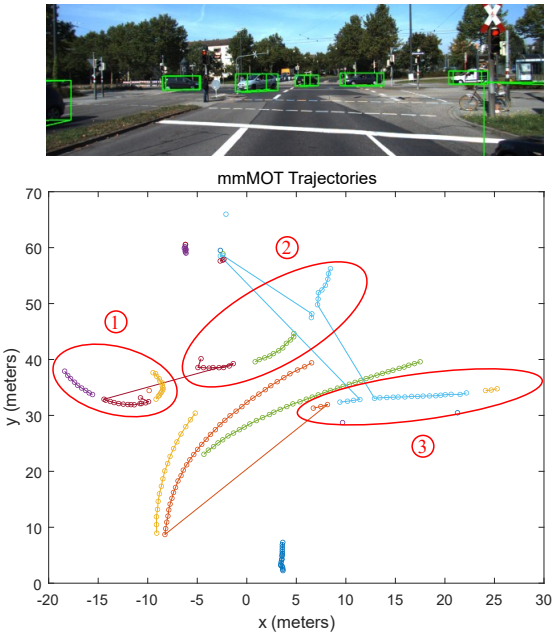
本工作选择了开源的相机图像与激光点云融合的跟踪方法 mmMOT[41] 作为基线比较方法来进行案例分析，并在结果的比较中选取了两种场景来阐述本方法的优越性：




(a) 地面真值




(b) JMODT（本方法）




(c) mmMOT

图 3-5　本方法和 mmMOT[41] 方法在十字路口场景中生成的 BEV 视角轨迹结果的对比。

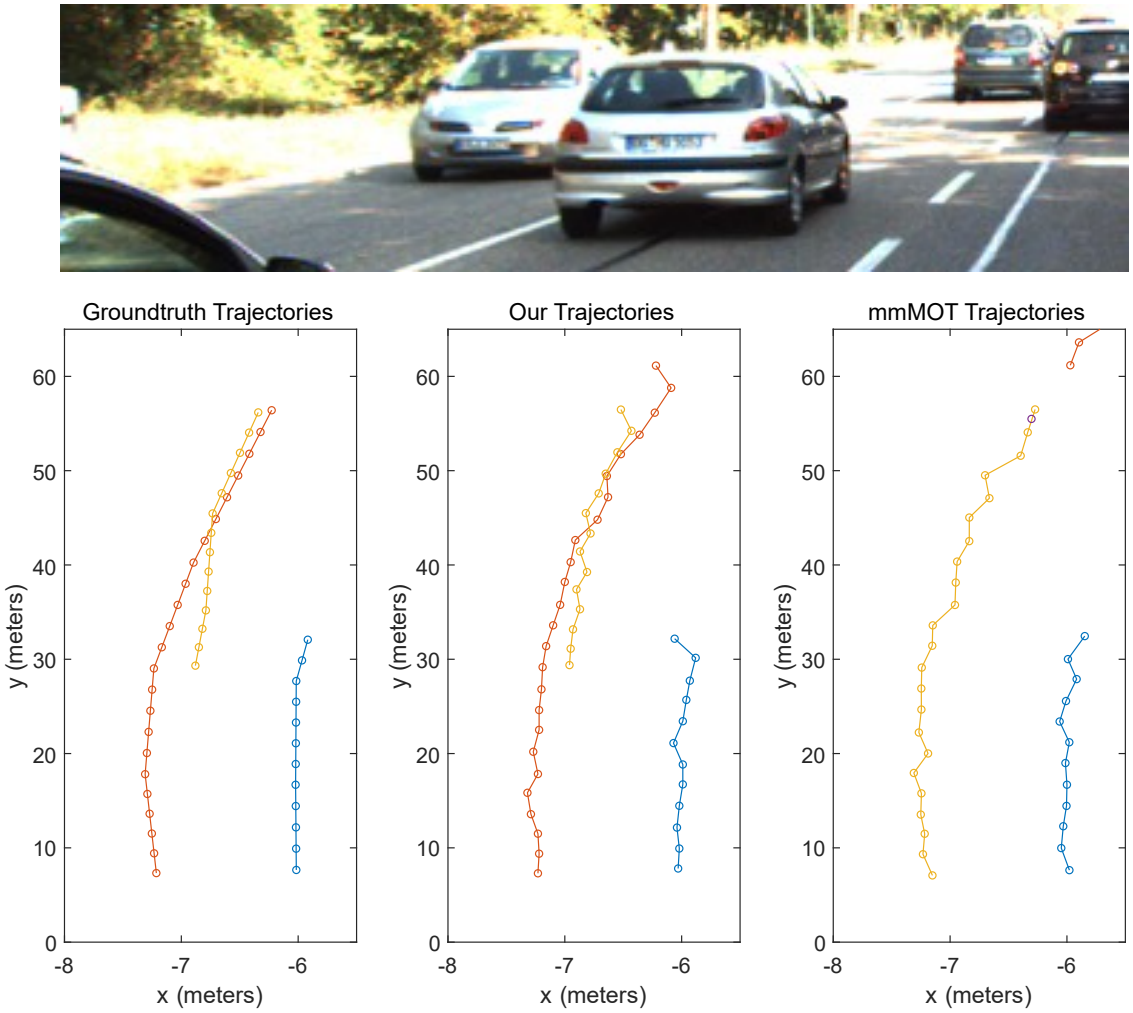



图 3-6　本方法和 mmMOT[41] 方法在拥挤场景中生成的 BEV 视角轨迹结果的对比。

（1）在十字路口处，车辆的运动复杂且遮挡较严重。本章提出的鲁棒的相似性计算模块能够帮助产生更长的轨迹和更少的 ID 交换，如图3-5所示。在红线圈出的区域内本方法的结果要明显优于 mmMOT，区域 1 内的轨迹表明了目标的复杂运动（掉头），区域 2 和区域 3 内的轨迹表明了目标的遮挡。

（2）在拥有相似外貌的车辆会车时，本章提出的进入-退出模块能够帮助产生新的轨迹，而 mmMOT 无法生成两条独立的轨迹，如图3-6所示。

### 3.4.5　测试结果

最终，将本方法在 KITTI 的测试集上生成的结果提交到官方的测试服务器上进行评估，与其他公开的相机与激光雷达融合方法的对比如表3-3所示。其中 AT 代表是否使用额外的数据进行训练（additional training），RT 代表每帧的运行时间（run-time）。数据来源自http://www.cvlibs.net/datasets/kitti/old_eval_tracking.php。为了更公平的比较，本方法只计算了跟踪阶段的运行时间，不包括检测阶段的运行

时间。在 2021 年论文发表时，本方法比所有其他的基于相机与激光雷达融合的方法在跟踪准确度和速度上都更好。本方法没有使用 KITTI 数据集的二维图像标签，也没有在其他大规模图像数据集（如 ImageNet[127]、COCO[115]等）上预训练模型，但仍然达到了较高的跟踪准确度。本方法使用了 JDT 范式，因此无需进行传感器数据的重载、扣取和冗余的特征提取，总体的计算时间要小于其他基于传感器融合和 TBD 范式的方法。

| | JDT | AT | FP↓ | FN↓ | IDSW↓ | MOTA↑ | RT↓ |
|---|---|---|---|---|---|---|---|
| JRMOT | × | ✓ | 772 | 4049 | 98 | 85.70 % | 0.07 s |
| mmMOT | × | ✓ | **711** | 4243 | 284 | 84.77 % | 0.02 s |
| JMODT | ✓ | × | 1244 | **3433** | **45** | **86.27** % | **0.01** s |

表 3-3　本方法与 JRMOT[44]和 mmMOT[41]在 KITTI 测试集的结果对比

## 3.5　本章小结

本章提出了一种端到端的、基于相机图像与激光点云融合的在线联合目标检测与跟踪网络 JMODT。JMODT 使用当前的二维、三维数据和历史轨迹的目标特征生成当前的三维目标包围盒和数据关联相关的置信度来进行在线的混合整数规划。本章提出的鲁棒的相似性计算模块和综合的数据关联方法能够有效地提升多目标跟踪的性能。在没有使用额外训练数据的情况下，本方法在 KITTI 排行榜的基于图像-点云融合的方法中取得了先进的性能，其中跟踪准确度达到 86.3%，每帧的运行时间小于 0.01 秒。由于多模态传感器融合的特性和联合目标检测与跟踪的特性，本方法适用于具有较高鲁棒性和实时性要求的在线自动驾驶应用。

# 第 4 章　三维多目标跟踪的离线优化

## 4.1　引言

上一章提出了一种基于相机与激光雷达融合的联合多目标检测与跟踪算法：JMODT，该方法属于在线方法，通过检测与跟踪模块的结合提高了整体的实时性。然而，在自动驾驶的障碍物感知中，除了在线和实时的应用需求外，还有许多离线的应用需求，如自动化数据标注等。离线设定对于多目标跟踪而言，主要优势在于以下三个方面：

（1）没有实时性要求，可以通过观测的集成提高观测的精确性。

（2）可不按时序应答，可以通过可信的匹配提高跟踪的稳定性。

（3）结果可反复修改，可以通过轨迹的优化提高输出的准确性。

尽管已有许多离线多目标跟踪算法的研究，目前的离线优化方法仍然有以下难点尚未解决：

（1）**精细的多模态感知结果集成**。自动驾驶中包括相机与激光雷达等多模态的传感器。相机图像的色彩信息和纹理信息较为丰富，并且有许多大规模数据集提供给模型训练，因此图像中的二维目标检测的结果往往比点云中的三维目标检测的结果更加精确，但二维目标检测不提供深度信息。目前的二维-三维目标后融合方法（如 CLOCs[128]、Fast-CLOCs[129]）都是将点云检测结果进行投影后转化为二维目标包围盒，并与图像检测结果通过 IoU 相似性进行合并。但是，由于三维包围盒可能包含了大量的被遮挡部分，投影后的二维包围盒会包含大量的非目标信息或是其他目标信息，从而导致无法匹配或是出现歧义。如图4-1所示。因此，通过包围盒投影的集成方法并不准确，需要一种更精细的目标对应方法以达到更准确的检测结果集成。

（2）**鲁棒的三维目标相似性计算**。不论是使用二分图[70]、网络流[101]还是层级聚类[105-106]等数据关联结构，都离不开准确的目标相似性度量或轨迹相似性度量。相似性度量通常包含外貌和运动两个方面。目前的外貌相似性计算方法主要是利用目标包围盒扣取区域图像信息进行 ReID。但是，如图4-1所示的遮挡使得包围盒扣取的图像信息具有歧义。因此，需要一种更准确的外貌与运动相似性计算方法进行目标与轨迹的匹配。

（3）**全局的轨迹重组与优化**。许多方法[104-105,130]基于聚类策略通过轨迹目标的 ReID 特征以及空间位置信息进行了目标和轨迹的合并，少数方法[106]还通过

ReID 特征进行了轨迹的拆分。然而，由于短轨迹的上下文信息较少，估计出的目标运动往往不准确，在进行轨迹合并时的成功率不高。进行轨迹拆分时，只利用单帧的外貌信息也容易导致拆分错误。因此，需要一种更加全局判断的方法对轨迹进行拆分与重组来更准确地优化轨迹。

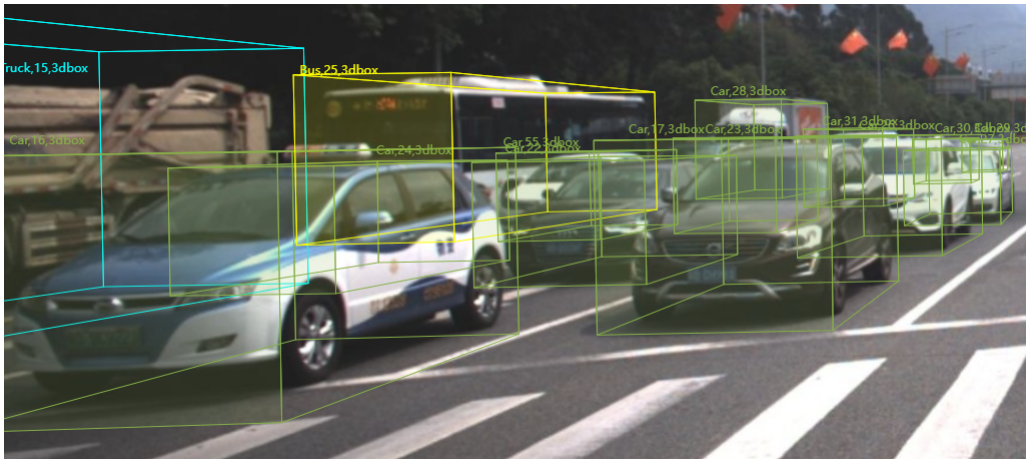



图 4-1　被遮挡的三维目标包围盒在图像上的投影容易产生歧义

针对以上难点，本章提出一个基于多模态融合和全局轨迹优化的离线三维多目标跟踪系统。本工作的主要贡献包括：

（1）基于点级别的投影对应和测试数据增强，开发了一个精确的多模态结果集成模块。

（2）基于二维实例特征提取和卡尔曼滤波器，开发了一个鲁棒的正反双向多目标跟踪模块。

（3）基于轨迹聚类和贪心算法，开发了一个高效的正反轨迹融合模块。

（4）基于线性插值和轨迹预测，开发了一个准确的轨迹修正与补全模块。

（5）在 KITTI 跟踪数据集[109]上进行实验，即使在目标检测精确度低的情况下，本方法在多目标跟踪准确度（MOTA）上优于最新的离线多目标跟踪方法。

## 4.2　系统架构

目前关于离线多目标跟踪的算法大多使用可解耦的 tracking-by-detection 范式。本方法的系统架构如图4-2所示包含三个模块：（1）多模态目标检测模块、（2）双向多目标跟踪模块和（3）轨迹优化模块。在多模态目标检测模块中，本工作使用现成的基于点云的三维目标检测网络和基于图像的二维实例分割网络进行多模态目标检测，并把检测结果进行优化和集成，作为跟踪模块的输入。在双向多目标跟踪模块中，本工作使用类似 DeepSORT[70]的架构进行在线多目标跟踪，根据时序的正反生成两种轨迹。在线多目标跟踪的基本流程为：首先通过2.3节中介绍的

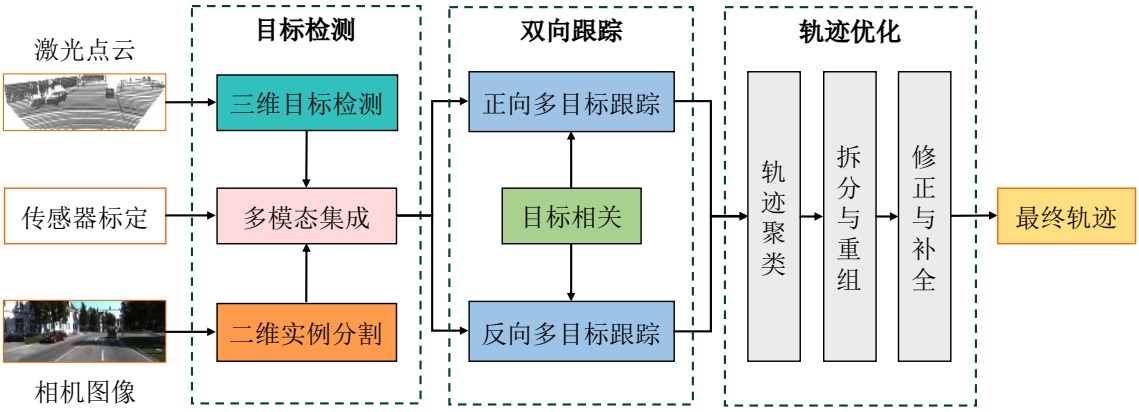



图 4-2　本工作提出的离线多目标跟踪系统架构

卡尔曼滤波器进行运动估计和预测，与二维实例特征提取网络结合，计算目标相似性；之后对相似性分数进行二分图最大匹配，匹配时使用匈牙利算法；最后对匹配结果进行阈值过滤，并通过2.7节中介绍的轨迹状态管理输出轨迹结果。在轨迹优化模块中，本工作对正反轨迹进行聚类与合并，并对融合后的轨迹进行修正和补全。

### 4.2.1　问题描述

基于上述的系统架构，本章提出的方法专注于解决以下三个问题：

（1）如何基于多模态的感知网络进行准确的观测结果筛选与集成？

（2）如何基于集成的观测结果进行鲁棒的相似性计算与稳定的多目标跟踪？

（3）如何基于正向与反向的跟踪结果进行轨迹的融合与优化？

## 4.3　本章提出的方法

### 4.3.1　三维目标检测的测试时间增强

通常情况下，基于点云的三维目标检测的精确度比基于图像的二维目标检测的精确度低，因此三维目标检测往往成为多模态结果融合的瓶颈。由于本工作属于离线应用，不需要达到实时性。因此，本工作使用了测试时间增强（TTA）来提高三维目标检测的精度。TTA 是指将数据增强后进行网络推理，并将推理结果通过数据增强的逆变换转回正常的坐标系，最后进行合并，如图4-3所示。

对于目标检测的 TTA，合并的方法通常采用正常的非极大值抑制（NMS）。除此之外，加权包围盒融合（Weighted Box Fusion，WBF）[131] 方法使用置信度作为融合权重将目标包围盒进行聚类合并，但需要调出一个最优的融合阈值。在本工作的实验过程中，直接使用 NMS 的效果优于使用 WBF。

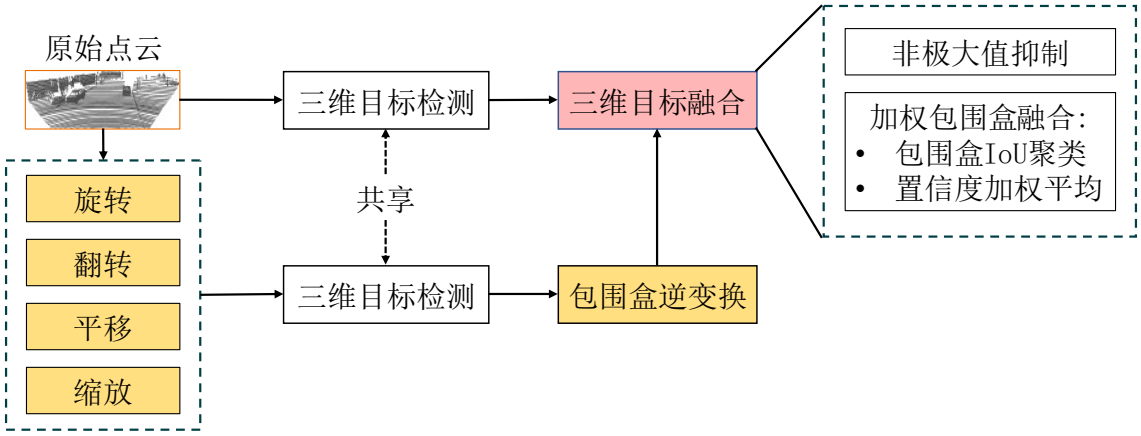



图 4-3　三维目标检测的测试时间增强

### 4.3.2　二维实例与三维目标检测的集成

为了避免框级别匹配中由于视角差异与目标遮挡导致的二维与三维目标对应错误，本工作提出使用更精细的点级别的目标对应方法：使用二维实例分割与三维目标点云分割来进行投影对应，如图4-4所示。

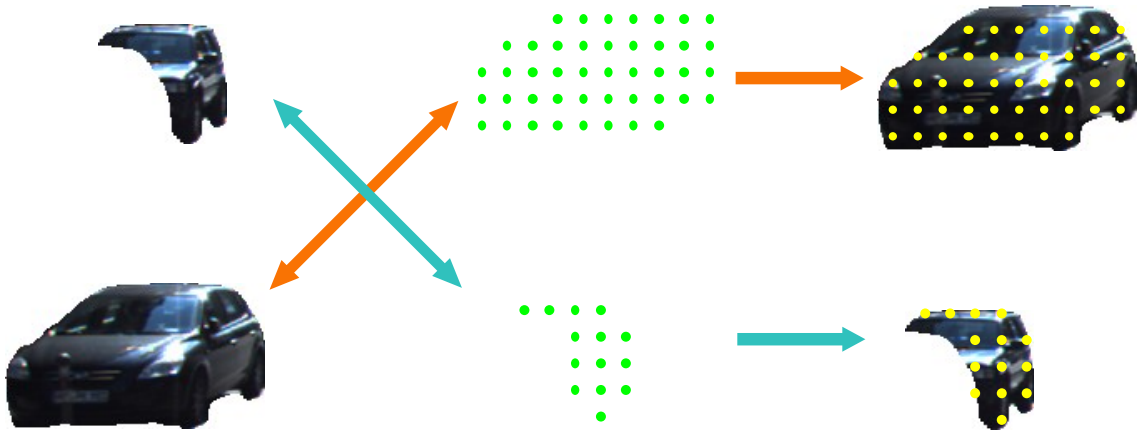


图 4-4　二维实例分割掩码与三维目标点云的对应

理论上点级别的对应是不存在对应误差的，但是实际中由于二维实例分割和三维目标检测都存在预测错误，并且传感器的几何标定与时间同步不精准，所以需要使用匈牙利算法，通过最大化对应点数量进行二分图匹配，缓解这些误差对融合结果的影响。具体的二维与三维目标结果集成算法的流程如算法4-1所示。本工作使用目标点云与实例掩码的重合数量除以目标点云数量作为目标匹配的相似性，并对匈牙利算法的匹配结果进行阈值过滤，仅保留相似性大于设定阈值 $\theta_p$ 的三维目标检测结果。

相比于 CLOCs[128]根据二维包围盒 IoU 和深度信息估计三维目标的置信度，本方法更直接地使用了对应点的数目，不需要模型训练且更具有解释性。在使用 TTA 后，三维观测目标的数量往往较多。而通过本工作提出的多模态结果集成方

算法 4-1　点级别的二维与三维目标结果集成算法

**输入:** 二维实例分割掩码 $S_{2d}$，三维目标包围盒 $B_{3d}$，点云 $M_{pc}$

**输出:** 集成后的三维目标包围盒 $B'_{3d}$

$P_{3d} = \text{crop}(M_{pc}, B_{3d})$ ;　// 扣取三维目标包围盒内的点云

$P_{proj} = \text{proj}(P_{3d}, \boldsymbol{K}, \boldsymbol{R}, \boldsymbol{t})$ ;　// 使用公式(2-3)计算目标点云到图像的投影坐标

$P_{2d} = \text{int}(P_{proj})$ ;　// 将投影坐标转为整数

$C = \frac{|P_{2d} \cap S_{2d}|}{|P_{3d}|}$ ;　// 计算与实例掩码的重合数量并除以目标点云数量

$A = \text{Hungarian}(C)$ ;　// 使用匈牙利算法进行最大匹配

$A = \text{filter}(A, C, \theta_p)$ ;　// 过滤小于阈值的匹配结果

$B'_{3d} = \text{retrieve}(B_{3d}, A)$ ;　// 输出匹配后的三维包围盒

**return** $B'_{3d}$

法进行下采样后，三维目标观测拥有了较高的质量和置信度，因此大大减少了多目标跟踪时的匹配干扰。

### 4.3.3　稳定的在线多目标跟踪

在使用卡尔曼滤波器进行目标的运动估计和预测时，本工作在原有设置[71]的基础上对目标方位角的角速度也进行估计。同时在轨迹第一次更新前还利用了轨迹与匹配目标之间的距离进行轨迹线速度与角速度的初始化，而不是简单地初始化为 0，这样能够让滤波器状态收敛地更快。

本工作使用了二维实例特征的余弦距离以及目标观测与预测的几何距离进行相似性计算。目标的几何相似性包括两部分，一个是公式(3-1)所示的 Distance-IoU 相似性，另一个则是公式(4-1)所示的方位角相似性。

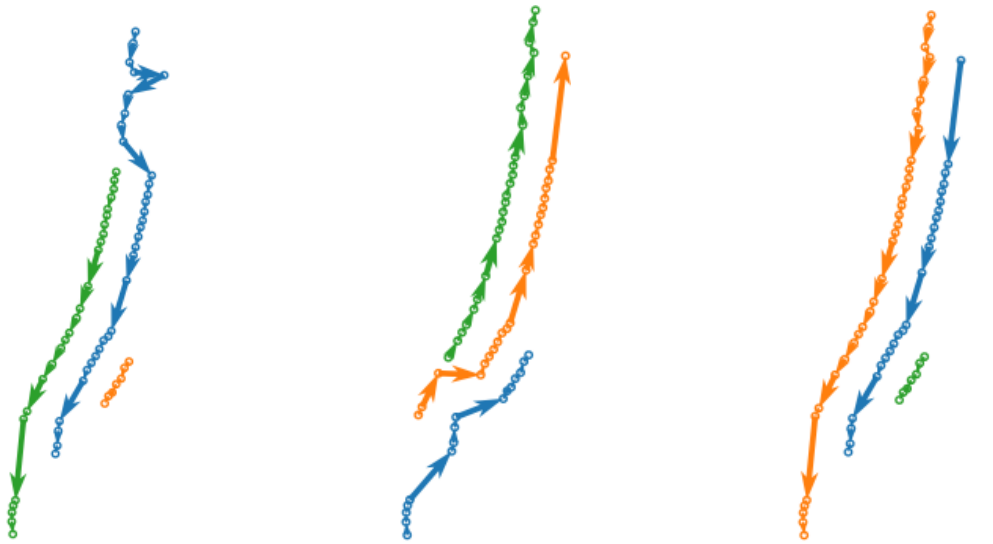
$$\forall i, \forall j, a_{i,j}^{rot} = 1 - \frac{f(|r_i - r_j|)}{\pi}, 0 \leqslant f(|r_i - r_j|) \leqslant \pi \tag{4-1}$$

由于目标检测的方位角不是十分准确，卡尔曼滤波器对角速度的估计不稳定。同时，本工作发现实例特征的质量也不高。因此，本工作将方位角相似性与外貌相似性仅用于匹配后的阈值过滤。设置较高的匹配阈值可以使数据关联结果的质量更高，增加跟踪的稳定性，被过滤的观测匹配结果仍然可以作为新轨迹进行后续的跟踪。

在轨迹状态管理方面，本工作在2.7节介绍的状态转移的基础上，对出生状态的轨迹进行保留，若轨迹成功进入跟踪状态，则将出生状态的轨迹也进行输出，以此生成更长的轨迹。该方法属于离线设定的轨迹管理方法，即不严格地按时序进行目标输出：将不确定的出生状态的轨迹等到确定后再输出。除此之外，本工作对于新的观测设置的丢失阈值要远小于已更新的轨迹的丢失阈值，这样能进一步降低假阳性输入对轨迹匹配的干扰。

### 4.3.4　正反双向轨迹的拆分与合并

在离线设定下，正时序与反时序的多目标跟踪结果可以进行信息互补。本工作提出一种融合正向轨迹与反向轨迹的方法。正向轨迹与反向轨迹产生差异的主要原因有两个：（1）由于在跟踪的初期轨迹的不确定性较高，而跟踪的末期不确定性较低，所以正向跟踪与反向跟踪在轨迹的首尾两端容易产生差异；（2）对于错误的检测，正向跟踪与反向跟踪的结果往往不一致。本课题通过保留置信度更高的共同轨迹，并对存在差异的轨迹进行重新组合，实现对轨迹的融合。融合正向与反向轨迹的流程如算法4-3所示。首先根据正反轨迹是否相交进行正反轨迹的聚类，如算法4-2所示，若聚类后的轨迹集合中的轨迹目标都属于不同时刻，则将集合中的轨迹合并，否则对集合进行轨迹拆分和重组。轨迹的聚类算法属于二分图的搜索，根据是否存在边（是否相交）对二分图的节点进行来回的聚类。轨迹的拆分与重组算法属于贪心算法，根据历史轨迹的长度进行贪心的连接。图4-5显示了一个聚类后的轨迹重组结果的例子。



(a) 正向轨迹　(b) 反向轨迹　(c) 重组后的轨迹

图 4-5　轨迹的拆分与重组

### 4.3.5　轨迹的修正与补全

在通过正反轨迹的融合之后，轨迹的连接准确度和置信度都得到了提升。在此基础上，对轨迹的包围盒进行修正和补全可以进一步提高结果的质量。

包围盒的修正包括两个方面：（1）大小的修正和（2）位置与方位角的修正。对于大小的修正，本工作使用置信度加权的方式，对轨迹中的所有包围盒大小进行平均。对于位置和方位角的修正，本工作尝试使用了卡尔曼滤波器的更新结果以及线性回归的结果，但最终的轨迹准确度没有得到提升。由于本系统的解耦性质，

算法 4-2　正向与反向轨迹的循环算法

**输入:** 正向轨迹的 ID 集合 $\boldsymbol{A}$，反向轨迹的 ID 集合 $\boldsymbol{B}$，其中 $\boldsymbol{A} \cap \boldsymbol{B} = \emptyset$
**输出:** 轨迹集群 $\boldsymbol{S}$

$\boldsymbol{S} = \emptyset, \boldsymbol{A'} = \boldsymbol{A}, \boldsymbol{B'} = \boldsymbol{B}$;
**while** $\boldsymbol{A'} \neq \emptyset$ *or* $\boldsymbol{B'} \neq \emptyset$ **do**
    $\boldsymbol{C}_a = \boldsymbol{C}_b = \emptyset$;
    **if** $\boldsymbol{A'} \neq \emptyset$ **then**
        $a = \text{pop}(\boldsymbol{A'})$;
        $\boldsymbol{C}_a = \boldsymbol{C}_a \cup a$;
        在 $\boldsymbol{B}$ 中找出所有与 $a$ 轨迹相交的反向轨迹 ID 集合 $\boldsymbol{D}$;
    **else**
        $b = \text{pop}(\boldsymbol{B'})$;
        $\boldsymbol{C}_b = \boldsymbol{C}_b \cup b$;
        在 $\boldsymbol{A}$ 中找出所有与 $b$ 轨迹相交的正向轨迹 ID 集合 $\boldsymbol{D}$;
    **end**
    $n = \text{len}(\boldsymbol{D})$;
    **while** $n > 0$ **do**
        **if** $\boldsymbol{D} \in \boldsymbol{B}$ **then**
            $t = \text{len}(\boldsymbol{B'})$;
        **else**
            $t = \text{len}(\boldsymbol{A'})$;
        **end**
        $\boldsymbol{D'} = \emptyset$ **for** $d \in \boldsymbol{D}$ **do**
            **if** $\boldsymbol{D} \in \boldsymbol{B}$ **then**
                $\boldsymbol{B'} = \boldsymbol{B'} \setminus d$;
                $\boldsymbol{C}_b = \boldsymbol{C}_b \cup d$;
                在 $\boldsymbol{A}$ 中找出所有与 $d$ 轨迹相交的正向轨迹 ID 集合 $\boldsymbol{E}$;
            **else**
                $\boldsymbol{A'} = \boldsymbol{A'} \setminus d$;
                $\boldsymbol{C}_a = \boldsymbol{C}_a \cup d$;
                在 $\boldsymbol{B}$ 中找出所有与 $d$ 轨迹相交的反向轨迹 ID 集合 $\boldsymbol{E}$;
            **end**
            $\boldsymbol{D'} = \boldsymbol{D'} \cup \boldsymbol{E}$;
        **end**
        **if** $\boldsymbol{D} \in \boldsymbol{B}$ **then**
            $n = \text{len}(\boldsymbol{B'}) - t$;
        **else**
            $n = \text{len}(\boldsymbol{A'}) - t$;
        **end**
        $\boldsymbol{D} = \boldsymbol{D'}$;
    **end**
    $\boldsymbol{S} = \boldsymbol{S} \cup \{\boldsymbol{C}_a, \boldsymbol{C}_b\}$;
**end**
**return** $\boldsymbol{S}$

算法 4-3　正向与反向轨迹的拆分与重组算法

**输入:** 正向轨迹，反向轨迹，轨迹集群 $\boldsymbol{S}$
**输出:** 融合后的轨迹 $\boldsymbol{T}$

```
T = ∅;
for s ∈ S do
    if s 中的目标都处于不同时刻 then
        将 s 合并为一条新轨迹并加入 T 中;
    else
        根据目标正反 ID 是否同时连续将 s 中的轨迹拆分成碎片;
        根据轨迹碎片端点在原轨迹中的序号从大到小排序，依次按照原轨迹的
          连接方式进行连接，若有目标时刻的冲突则跳过，若已连接则不再连接;
        将连接后的若干条新轨迹加入 T 中;
    end
end
return T
```

在包围盒的位置与方位角的修正方面可以使用如 Offboard3D[107] 和 Auto4D[108] 等深度学习的方法进行代替。

包围盒的补全包括两个方面：（1）轨迹中部的补全和（2）轨迹首尾的拓展。对于轨迹中部的补全，可以使用线性插值和卡尔曼滤波预测等方法。本工作使用了线性插值，并设置了轨迹的最大间隔，超过最大间隔的轨迹将不进行补全。对于轨迹首尾的拓展，本工作尝试使用了卡尔曼滤波器的预测结果，但预测结果并不准确。在轨迹拓展方面，可以使用轨迹预测相关的深度学习方法进行代替。为了去除不准确的包围盒，本工作对补全的结果进行了合理性的判断。包围盒的筛选分为两步：（1）若补全的包围盒与其他轨迹已有的包围盒有重叠，则直接去除，（2）以补全的包围盒内的点云数量作为置信度，对所有补全的包围盒进行置信度过滤和非极大值抑制。

## 4.4　实验验证

### 4.4.1　数据集

本工作依然使用 KITTI 跟踪数据集[109]进行车辆的多目标跟踪，具体已在3.4.1节中介绍。本工作针对车辆类别，使用了全部的训练集和验证集的数据进行多目标跟踪准确性的评估。

### 4.4.2　具体实现

#### 4.4.2.1　三维目标检测网络

离线应用中通常使用 TBD 范式进行目标检测与跟踪的解耦，这样就可以选择任何一种性能优越的三维目标检测器获取检测结果。本工作使用开源的 Voxel-RCNN[59]作为点云模态的三维目标检测网络。VoxelRCNN 是一个经典的基于体素和锚点的二阶段目标检测网络，结构相对简单且具有较高运行速度。本工作将 VoxelRCNN 在 KITTI 三维目标检测数据集[109]上进行训练。在实际的数据标注过程中，需要在未标注数据上对模型进行跨域训练。为了方便实验，本工作不考虑网络模型跨域，直接在 KITTI 跟踪数据集上进行验证。

#### 4.4.2.2　二维实例分割网络

由于 TBD 的解耦性质，本工作可以使用任何一种二维实例分割网络获取实例分割结果。本工作使用开源的 SpatialEmbedding[132]来实现二维实例分割。其中二维实例分割网络 SpatialEmbedding 为 ERFNet[133]的拓展版本，使用了多个解码器分支预测空间位置和 $\sigma$ 等变量作为后处理中的聚类算法的输入。

#### 4.4.2.3　二维实例 ReID 特征提取网络

与常规的基于二维包围盒的 ReID 不同，二维实例掩码与二维目标包围盒相比有着不同的大小、形状和像素点数量，但有着更精细的前景划分。本工作使用 Point-Track[134]来实现二维实例 embedding 的提取。PointTrack 也使用了 SpatialEmbedding 的网络架构，并将其在 KINS[135]数据集上预训练的模型迁移到 KITTI-MOTS[77]数据集上做了微调（finetuning）。PointTrack 中的 embedding 提取网络采用类似点云的 PointNet[7]架构，将实例前景的像素和周围部分背景的像素以类似点云的方式采样并提取 embedding。

#### 4.4.2.4　超参数设置

本工作在测试时间增强中采用的数据增强包括：（1）沿 x 轴左右翻转；（2）缩放 $\pm 0.05$ 倍；（3）旋转 $\pm\frac{\pi}{8}$ 和 $\pm\frac{\pi}{4}$；（4）x 轴前后平移 5 米和 y 轴左右平移 5 米。在数据关联中使用的超参数包括：（1）DIoU 相似性阈值 $\theta_{DIoU} = 0.5$；方位角相似性阈值 $\theta_r = 0.5$（2）。在轨迹状态管理中使用的超参数包括：（1）新目标的丢失阈值 $\theta_{miss} = 3$；（2）已更新轨迹的丢失阈值 $\theta_{miss} = 13$；（3）轨迹最小长度（命中阈值）$\theta_{hit} = 3$。在轨迹包围盒补全中使用的超参数包括：（1）最大插值间隔为 4；（2）包围盒置信度阈值（最少点云数量）为 2。

### 4.4.3　消融实验

本工作依次针对三维目标检测的测试数据增强、多模态感知结果集成、正反轨迹合并、轨迹包围盒加权平均以及轨迹线性插值补全进行消融实验。对于观测的集成，本工作对比了是否使用 TTA 和二维三维结果融合的检测结果。从表4-1中可以看出，加入了 TTA 后的观测数量增加了一倍，同时目标的置信度都很高，通过多模态集成可以有效地将假阳性观测去除，最终达到了更高的检测平均精度。

| TTA | 多模态集成 | 观测数量 | 最优 $\theta_{cls}$ | AP@11↑ | AP@40↑ |
|---|---|---|---|---|---|
| × | × | 42,985 | 0.6 | 88.54 % | 89.50 % |
| × | ✓ | 30,436 | 0.2 | 88.67 % | 90.03 % |
| ✓ | × | 86,866 | 0.75 | 88.73 % | **91.07** % |
| ✓ | ✓ | 32,585 | 0.2 | **88.85** % | 90.18 % |

表 4-1　观测预处理的目标检测实验结果

本工作评估了对观测结果集成方法和正反轨迹合并方法对多目标跟踪的影响。从表4-2中可以看出，加上了 TTA、多模态集成或正反轨迹合并模块后比不加入模块的多目标跟踪准确度（MOTA 和 HOTA）都要更高。

| TTA | 多模态集成 | 正反合并 | MOTA↑ | HOTA↑ |
|---|---|---|---|---|
| × | × | × | 85.92 % | 70.03 % |
| × | ✓ | × | 88.04 % | 79.68 % |
| × | × | ✓ | 86.08 % | 79.24 % |
| × | ✓ | ✓ | 88.13 % | 79.77 % |
| ✓ | × | × | 84.98 % | 79.01 % |
| ✓ | ✓ | × | 89.51 % | 80.73 % |
| ✓ | × | ✓ | 85.24 % | 79.13 % |
| ✓ | ✓ | ✓ | **89.68** % | **80.79** % |

表 4-2　观测集成模块与正反轨迹合并模块的多目标跟踪实验结果

对于轨迹的修正和补全，本工作也进行了消融实验。如表4-3所示，加入了包围盒大小的置信度加权平均和轨迹中部的线性插值补全后，跟踪准确度都有所提升。

| 加权平均 | 线性插值 | MOTA↑ | HOTA↑ |
|---|---|---|---|
| × | × | 89.68 % | 80.79 % |
| ✓ | × | 89.72 % | 81.29 % |
| × | ✓ | 89.88 % | 80.95 % |
| ✓ | ✓ | **89.90** % | **81.45** % |

表 4-3　包围盒修正模块的多目标跟踪实验结果

### 4.4.4　与最新方法的比较

本方法与当前 KITTI 跟踪基准中最新的方法 VirConv Track[136-137]进行了比较，如表4-4所示。本工作使用 VirConv Track 的开源代码进行复现，使用 KITTI 的全部有标签数据（共 21 个序列）。VirConv Track 使用了更先进的多模态三维目标检测方法，其检测精度比使用本方法集成之后的平均精度要高约 6%，但本方法在多目标跟踪方面的在线 MOTA 与离线 MOTA 指标都达到了更高的性能。在 HOTA 上，本方法的准确度略低于 VirConv Track，但本方法使用了更多的离线模块与技巧，因此在离线设定上的提升幅度更大。

| | 目标检测 AP@40↑ | 在线跟踪 MOTA↑ | 在线跟踪 HOTA↑ | 离线跟踪 MOTA↑ | 离线跟踪 HOTA↑ |
|---|---|---|---|---|---|
| VirConv Track | **96.01** % | 85.56 % | **82.40** % | 86.09 % (+0.53 %) | **82.79** % (+0.39 %) |
| 本方法（未集成输入） | 89.50 % | 83.00 % | 77.20 % | 86.60 % (+**3.60** %) | 80.26 % (+**3.06** %) |
| 本方法（已集成输入） | 90.18 % | **87.00** % | 79.04 % | **89.90** % (+2.90 %) | 81.45 % (+2.41 %) |

表 4-4　本方法与最新方法（VirConv Track[136-137]）在 KITTI 跟踪数据集的结果对比

## 4.5　本章小结

本章提出了一种基于相机与激光雷达融合的离线多目标跟踪系统。本系统将各模块解耦，使用任意的三维目标检测网络和二维实例分割网络进行多模态结果的集成，并使用改进后的在线多目标跟踪算法生成正反双向的轨迹，最后对正反轨迹进行融合和后处理优化。本章提出的多模态目标集成方法、正反轨迹融合方法以及轨迹修正与补全方法能够有效地提升轨迹的准确性。在没有进行模型训练的情况下，本章提出的优化模块使目标检测精度提升 0.68%，在线跟踪的 MOTA

提升 4%、HOTA 提升 1.84%，离线跟踪相比于在线跟踪 MOTA 提升 3.6%、HOTA 提升 3.06%，并且总体性能在 MOTA 上优于当前公开的最新方法（89.90%）。由于模块解耦的特性，本系统适用于任何先进的三维目标检测方法和在线三维多目标跟踪方法，无需额外训练，为数据集的自动化标注提供了基础框架。

# 结 论

本文以自动驾驶障碍物感知中的三维目标检测与跟踪为研究内容，提出了一种基于联合目标检测与跟踪的在线多目标跟踪解决方案和一种基于多模态感知结果和正反双向跟踪结果集成的离线多目标跟踪解决方案。本工作的主要创新点和贡献总结如下：

（1）针对在线检测与跟踪算法的研究。本文在充分考虑了三维目标检测与目标重识别的网络特性的情况下，提出了一种端到端的神经网络 JMODT，将二阶段的多模态三维目标检测网络与目标相关网络进行特征共享和联合训练，并设计了一种鲁棒的多模态外貌和三维运动信息的相似性度量，以及提出一种基于观测不确定性和目标相关分数的综合数据关联方法。本工作在 KITTI 跟踪数据集上进行验证。在多模态三维多目标跟踪的方法中，本文提出的方法在 MOTA 和运行速度上都超过了基线方法，其中测试集的 MOTA 达到 86.27%，运行时间小于 0.01 秒，达到了自动驾驶在线感知的准确性、鲁棒性和实时性要求。

（2）针对离线检测与跟踪算法的研究。本文在充分考虑了二维与三维目标的几何特性以及多目标跟踪数据关联原理的情况下，提出了一种基于集成思想的离线多目标跟踪系统，包括对跟踪输入、跟踪过程和跟踪结果的优化，即多模态感知结果的集成、正反双向跟踪结果的集成以及轨迹的后处理优化。本工作同样在 KITTI 跟踪数据集上进行验证。本文提出的方法即使在输入精度更低的情况下，在 MOTA 上超过了最新的离线跟踪算法，其中验证集的 MOTA 达到了 89.9%。此外，得益于各模块之间的解耦，本系统适用于任何先进的在线检测与跟踪算法的嵌入，为数据集的自动化标注提供了基础框架。

虽然本文提出的在线与离线方法在一定程度上提高了三维目标检测与跟踪的性能，但仍有许多可改进之处：

（1）联合目标检测、重识别和运动估计。本工作提出的在线方法使用的 JDT 范式属于联合目标检测与重识别，但运动估计也可通过共享特征的方式进行网络训练，以此取代卡尔曼滤波器来提供运动相似性信息。使用传统的卡尔曼滤波器的优势在于算法较为稳定、具有可解释性、可人工定义运动模型并进行调参，但不足之处也很明显：卡尔曼滤波器需要较长时间的输入才能收敛，在跟踪前期不确定性较大且很依赖初始值的设定。通过网络训练的方式可以提取更丰富的上下文信息来帮助进行运动估计，但需要进行多帧联合特征提取。在1.2.5节中介绍了许

多联合目标检测与重识别、联合目标检测与运动估计的方法，但很少有将三者同时联合的方法。使用三个任务进行联合训练理论上能够提取出更鲁棒的特征，但是对特征提取的方法上要求更高才能使网络更好的收敛。

（2）相机图像与激光点云的 BEV 时序融合。由于本工作提出的在线方法联合了目标检测与相关网络，目标特征的质量变得尤为关键，通过多帧数据的补全理论上可以有效地提升特征的质量，尤其是在目标被遮挡等数据不全的情况下。在1.2.3节中已论述了相机图像与激光点云时序融合的最新相关方法，本工作尝试使用了 VoxelRCNN[59] 代替 EPNet 作为特征提取和目标检测的架构，并在 BEV 颈网络上使用 ConvGRU 对多帧的特征进行融合。但可能是由于 KITTI 数据集无法得到准确的定位信息，无法将数据输入和特征准确地转换到全局坐标系，因此最终网络的训练难以收敛，检测精度和跟踪准确度都大幅下降。若使用 nuscenes[113] 或其他具有准确的自车定位信息的多模态、多任务数据集进行训练可能会达到更好的效果。

（3）使用 transformer 架构进行全局的交叉注意力交互。本工作提出的在线方法使用的是基于区域的 R-CNN 架构，在联合目标检测与重识别时并没有将区域特征与当前和历史的全局特征图进行交互，而只是通过取平均值的方式获取全局目标的特征。这种粗暴的方式可能会使网络模型难以全局的推理。在1.2.5节中介绍了基于 transformer 的联合目标检测与跟踪方法。若使用 transformer 架构则可以使用当前和历史轨迹的区域特征作为查询向量，与当前的全局特征图在解码器中进行交叉注意力的交互，得到更综合的目标相关性。

（4）利用目标的外貌信息进行优化。本工作提出的离线方法尝试使用了二维实例 embedding 提取网络 PointTrack[134]，但从实际效果来看，该方法提取的特征不能够很好地区分目标。若使用其他基于图像的目标特征提取网络或基于点云的目标特征提取网络，可能会达到更好的跟踪效果。

（5）利用目标方位角进行轨迹优化。本工作提出的离线方法考虑到目标方位角的不准确性，最终只将目标方位角的相似性用于匹配结果的过滤。若能够通过滤波器和神经网路将方位角进行稳定的平滑，可以将目标方位角的相似性用于数据关联和正反轨迹的拆分与重组，从而达到更高的轨迹准确度。

（6）利用神经网络进行轨迹修正和预测。本工作提出的离线方法只对轨迹的目标大小进行平均以及对轨迹中部进行插值补全。若使用准确度更高的深度神经网络方法，还可以进行轨迹位置和方位角的修正，以及通过轨迹预测进行轨迹首尾两端的延展。

（7）利用目标分类方法对新增目标进行置信度判断。本工作提出的离线方法

使用了新增目标内的点云数量作为目标的置信度。若使用二阶段目标检测网络中的 R-CNN 网络进行判断，可以得到更准确的目标置信度，从而提高轨迹的准确度。

# 参考文献


[1] 中华人民共和国中央人民政府. 国务院办公厅关于印发新能源汽车产业发展规划（2021—2035 年）的通知[EB/OL]. 2020. http://www.gov.cn/zhengce/content/2020-11/02/content_5556716.htm.

[2] 中华人民共和国中央人民政府.《智能网联汽车技术路线图 2.0》日前发布——汽车智能网联是未来竞争焦点[EB/OL]. 2020. http://www.gov.cn/xinwen/2020-11/19/content_5562464.htm.

[3] TEAM T A. Tesla autopilot[EB/OL]. 2023. https://www.tesla.com/autopilot.

[4] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[5] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.

[6] LIU Z, MAO H, WU C Y, et al. A convnet for the 2020s[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11976-11986.

[7] QI C R, SU H, MO K, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 652-660.

[8] QI C R, YI L, SU H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in neural information processing systems, 2017, 30.

[9] ZHANG M, CUI Z, NEUMANN M, et al. An end-to-end deep learning architecture for graph classification[C]//Proceedings of the AAAI conference on artificial intelligence: volume 32. 2018.

[10] ZHOU Y, TUZEL O. Voxelnet: End-to-end learning for point cloud based 3d object detection [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4490-4499.

[11] LANG A H, VORA S, CAESAR H, et al. Pointpillars: Fast encoders for object detection from point clouds[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 12697-12705.

[12] ZHOU Y, SUN P, ZHANG Y, et al. End-to-end multi-view fusion for 3d object detection in lidar point clouds[C]//Conference on Robot Learning. PMLR, 2020: 923-932.

[13] YAN Y, MAO Y, LI B. Second: Sparsely embedded convolutional detection[J]. Sensors, 2018, 18(10): 3337.

[14] GRAHAM B, ENGELCKE M, VAN DER MAATEN L. 3d semantic segmentation with submanifold sparse convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 9224-9232.

[15] CHEN Y, LI Y, ZHANG X, et al. Focal sparse convolutional networks for 3d object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 5428-5437.

[16] LIU Z, TANG H, AMINI A, et al. BEVFusion: Multi-Task Multi-Sensor Fusion with Unified Bird's-Eye View Representation[A]. 2022.

[17] LI Y, GE Z, YU G, et al. Bevdepth: Acquisition of reliable depth for multi-view 3d object detection[A]. 2022.

[18] HUANG D, CHEN Y, DING Y, et al. Rethinking Dimensionality Reduction in Grid-based 3D Object Detection[A]. 2022.

[19] MA Y, WANG T, BAI X, et al. Vision-centric bev perception: A survey[A]. 2022.

[20] CAN Y B, LINIGER A, UNAL O, et al. Understanding bird's-eye view of road semantics using an onboard camera[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 3302-3309.

[21] SONG L, WU J, YANG M, et al. Stacked homography transformations for multi-view pedestrian detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 6049-6057.

[22] REIHER L, LAMPE B, ECKSTEIN L. A sim2real deep learning approach for the transformation of images from multiple vehicle-mounted cameras to a semantically segmented image in bird's eye view[C]//2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC). IEEE, 2020: 1-7.

[23] HOU Y, ZHENG L, GOULD S. Multiview detection with feature perspective transformation [C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part VII 16. Springer, 2020: 1-18.

[24] GU J, WU B, FAN L, et al. Homography loss for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1080-1089.

[25] WANG Y, CHAO W L, GARG D, et al. Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 8445-8453.

[26] YOU Y, WANG Y, CHAO W L, et al. Pseudo-lidar++: Accurate depth for 3d object detection in autonomous driving[A]. 2019.

[27] MA X, WANG Z, LI H, et al. Accurate monocular 3d object detection via color-embedded 3d reconstruction for autonomous driving[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6851-6860.

[28] MA X, LIU S, XIA Z, et al. Rethinking pseudo-lidar representation[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XIII 16. Springer, 2020: 311-327.

[29] QIAN R, GARG D, WANG Y, et al. End-to-end pseudo-lidar for image-based 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 5881-5890.

[30] PHILION J, FIDLER S. Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XIV 16. Springer, 2020: 194-210.

[31] HUANG J, HUANG G, ZHU Z, et al. Bevdet: High-performance multi-camera 3d object detection in bird-eye-view[A]. 2021.

[32] READING C, HARAKEH A, CHAE J, et al. Categorical depth distribution network for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 8555-8564.

[33] LI Q, WANG Y, WANG Y, et al. Hdmapnet: An online hd map construction and evaluation framework[C]//2022 International Conference on Robotics and Automation (ICRA). IEEE, 2022: 4628-4634.

[34] YANG W, LI Q, LIU W, et al. Projecting your view attentively: Monocular road scene layout estimation via cross-view transformation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 15536-15545.

[35] WANG Y, GUIZILINI V C, ZHANG T, et al. Detr3d: 3d object detection from multi-view images via 3d-to-2d queries[C]//Conference on Robot Learning. PMLR, 2022: 180-191.

[36] LIU Y, WANG T, ZHANG X, et al. Petr: Position embedding transformation for multi-view 3d object detection[C]//Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXVII. Springer, 2022: 531-548.

[37] LI Z, WANG W, LI H, et al. Bevformer: Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers[C]//Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part IX. Springer, 2022: 1-18.

[38] YAN J, LIU Y, SUN J, et al. Cross Modal Transformer via Coordinates Encoding for 3D Object Dectection[A]. 2023.

[39] CHEN X, MA H, WAN J, et al. Multi-view 3d object detection network for autonomous driving [C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2017: 1907-1915.

[40] KU J, MOZIFIAN M, LEE J, et al. Joint 3d proposal generation and object detection from view aggregation[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018: 1-8.

[41] ZHANG W, ZHOU H, SUN S, et al. Robust multi-modality multi-object tracking[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 2365-2374.

[42] QI C R, LIU W, WU C, et al. Frustum pointnets for 3d object detection from rgb-d data[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 918-927.

[43] WANG Z, JIA K. Frustum convnet: Sliding frustums to aggregate local point-wise features for amodal 3d object detection[C]//2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2019: 1742-1749.

[44] SHENOI A, PATEL M, GWAK J, et al. Jrmot: A real-time 3d multi-object tracker and a new large-scale dataset[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 10335-10342.

[45] BAI X, HU Z, ZHU X, et al. Transfusion: Robust lidar-camera fusion for 3d object detection with transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1090-1099.

[46] VORA S, LANG A H, HELOU B, et al. Pointpainting: Sequential fusion for 3d object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 4604-4612.

[47] XU S, ZHOU D, FANG J, et al. Fusionpainting: Multimodal fusion with adaptive attention for 3d object detection[C]//2021 IEEE International Intelligent Transportation Systems Conference (ITSC). IEEE, 2021: 3047-3054.

[48] WANG C, MA C, ZHU M, et al. Pointaugmenting: Cross-modal augmentation for 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 11794-11803.

[49] HUANG T, LIU Z, CHEN X, et al. Epnet: Enhancing point features with image semantics for 3d object detection[C]//European Conference on Computer Vision. Springer, 2020: 35-52.

[50] LIU Z, HUANG T, LI B, et al. EPNet++: Cascade bi-directional fusion for multi-modal 3D object detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.

[51] YOO J H, KIM Y, KIM J, et al. 3d-cvf: Generating joint camera and lidar features using cross-view spatial feature fusion for 3d object detection[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXVII 16. Springer, 2020: 720-736.

[52] LIANG T, XIE H, YU K, et al. Bevfusion: A simple and robust lidar-camera fusion framework [A]. 2022.

[53] MERSCH B, CHEN X, BEHLEY J, et al. Self-supervised point cloud prediction using 3D spatio-temporal convolutional networks[C]//Conference on Robot Learning. PMLR, 2022: 1444-1454.

[54] HUANG J, HUANG G. Bevdet4d: Exploit temporal cues in multi-camera 3d object detection [A]. 2022.

[55] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.

[56] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer, 2015: 234-241.

[57] SHI S, WANG X, LI H. Pointrcnn: 3d object proposal generation and detection from point cloud[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 770-779.

[58] SHI S, GUO C, JIANG L, et al. Pv-rcnn: Point-voxel feature set abstraction for 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10529-10538.

[59] DENG J, SHI S, LI P, et al. Voxel r-cnn: Towards high performance voxel-based 3d object detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 35. 2021: 1201-1209.

[60] YIN T, ZHOU X, KRAHENBUHL P. Center-based 3d object detection and tracking[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 11784-11793.

[61] MISRA I, GIRDHAR R, JOULIN A. An end-to-end transformer model for 3d object detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 2906-2917.

[62] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.

[63] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.

[64] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.

[65] COMANICIU D, RAMESH V, MEER P. Real-time tracking of non-rigid objects using mean shift[C]//Proceedings IEEE Conference on Computer Vision and Pattern Recognition. CVPR 2000 (Cat. No. PR00662): volume 2. IEEE, 2000: 142-149.

[66] ASLANI S, MAHDAVI-NASAB H. Optical flow based moving object detection and tracking for traffic surveillance[J]. International Journal of Electrical, Computer, Energetic, Electronic and Communication Engineering, 2013, 7(9): 1252-1256.

[67] HENRIQUES J F, CASEIRO R, MARTINS P, et al. High-speed tracking with kernelized correlation filters[J]. IEEE transactions on pattern analysis and machine intelligence, 2014, 37(3): 583-596.

[68] BERTINETTO L, VALMADRE J, HENRIQUES J F, et al. Fully-convolutional siamese networks for object tracking[C]//Computer Vision–ECCV 2016 Workshops: Amsterdam, The Netherlands, October 8-10 and 15-16, 2016, Proceedings, Part II 14. Springer, 2016: 850-865.

[69] BEWLEY A, GE Z, OTT L, et al. Simple online and realtime tracking[C]//2016 IEEE international conference on image processing (ICIP). IEEE, 2016: 3464-3468.

[70] WOJKE N, BEWLEY A, PAULUS D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE international conference on image processing (ICIP). IEEE, 2017: 3645-3649.

[71] WENG X, KITANI K. A baseline for 3d multi-object tracking: volume 1[A]. 2019: 6.

[72] ZHANG Y, SUN P, JIANG Y, et al. Bytetrack: Multi-object tracking by associating every detection box[C]//Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXII. Springer, 2022: 1-21.

[73] CHUNG J, GULCEHRE C, CHO K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[A]. 2014.

[74] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

[75] KIM C, LI F, REHG J M. Multi-object tracking with neural gating using bilinear lstm[C]// Proceedings of the European conference on computer vision (ECCV). 2018: 200-215.

[76] HU H N, CAI Q Z, WANG D, et al. Joint monocular 3D vehicle detection and tracking[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 5390-5399.

[77] VOIGTLAENDER P, KRAUSE M, OSEP A, et al. Mots: Multi-object tracking and segmentation[C]//Proceedings of the ieee/cvf conference on computer vision and pattern recognition. 2019: 7942-7951.

[78] WANG Z, ZHENG L, LIU Y, et al. Towards real-time multi-object tracking[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16. Springer, 2020: 107-122.

[79] REDMON J, FARHADI A. Yolov3: An incremental improvement[A]. 2018.

[80] ZHANG Y, WANG C, WANG X, et al. Fairmot: On the fairness of detection and re-identification in multiple object tracking[J]. International Journal of Computer Vision, 2021, 129: 3069-3087.

[81] ZHOU X, WANG D, KRÄHENBÜHL P. Objects as points[A]. 2019.

[82] LIANG C, ZHANG Z, ZHOU X, et al. Rethinking the competition between detection and ReID in multiobject tracking[J]. IEEE Transactions on Image Processing, 2022, 31: 3182-3196.

[83] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.

[84] KENDALL A, GAL Y, CIPOLLA R. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7482-7491.

[85] FEICHTENHOFER C, PINZ A, ZISSERMAN A. Detect to track and track to detect[C]// Proceedings of the IEEE international conference on computer vision. 2017: 3038-3046.

[86] BERGMANN P, MEINHARDT T, LEAL-TAIXE L. Tracking without bells and whistles[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 941-951.

[87] PENG J, WANG C, WAN F, et al. Chained-tracker: Chaining paired attentive regression results for end-to-end joint multiple-object detection and tracking[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part IV 16. Springer, 2020: 145-161.

[88] PANG B, LI Y, ZHANG Y, et al. Tubetk: Adopting tubes to track multi-object in a one-step training model[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 6308-6318.

[89] ZHOU X, KOLTUN V, KRÄHENBÜHL P. Tracking objects as points[C]//European Conference on Computer Vision. Springer, 2020: 474-490.

[90] TOKMAKOV P, LI J, BURGARD W, et al. Learning to track with object permanence[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10860-10869.

[91] BALLAS N, YAO L, PAL C, et al. Delving deeper into convolutional networks for learning video representations[A]. 2015.

[92] LUO W, YANG B, URTASUN R. Fast and furious: Real time end-to-end 3d detection, tracking and motion forecasting with a single convolutional net[C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2018: 3569-3577.

[93] WU H, LI Q, WEN C, et al. Tracklet Proposal Network for Multi-Object Tracking on Point Clouds.[C]//IJCAI. 2021: 1165-1171.

[94] SUN P, CAO J, JIANG Y, et al. Transtrack: Multiple object tracking with transformer[A]. 2020.

[95] MEINHARDT T, KIRILLOV A, LEAL-TAIXE L, et al. Trackformer: Multi-object tracking with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 8844-8854.

[96] ZHU T, HILLER M, EHSANPOUR M, et al. Looking beyond two frames: End-to-end multi-object tracking using spatial and temporal transformers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.

[97] RUPPEL F, FAION F, GLÄSER C, et al. Transformers for multi-object tracking on point clouds [C]//2022 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2022: 852-859.

[98] ZIMMER W, RANGESH A, TRIVEDI M. 3d bat: A semi-automatic, web-based 3d annotation toolbox for full-surround, multi-modal data streams[C]//2019 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2019: 1816-1821.

[99] WANG B, WU V, WU B, et al. Latte: accelerating lidar point cloud annotation via sensor fusion, one-click annotation, and tracking[C]//2019 IEEE Intelligent Transportation Systems Conference (ITSC). IEEE, 2019: 265-272.

[100] LI E, WANG S, LI C, et al. Sustech points: A portable 3d point cloud interactive annotation platform system[C]//2020 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2020: 1108-1115.

[101] ZHANG L, LI Y, NEVATIA R. Global data association for multi-object tracking using network flows[C]//2008 IEEE conference on computer vision and pattern recognition. IEEE, 2008: 1-8.

[102] BERCLAZ J, FLEURET F, TURETKEN E, et al. Multiple object tracking using k-shortest paths optimization[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 33 (9): 1806-1819.

[103] WANG C, WANG Y, WANG Y, et al. muSSP: Efficient min-cost flow algorithm for multi-object tracking[J]. Advances in neural information processing systems, 2019, 32.

[104] ZHANG S, GONG Y, HUANG J B, et al. Tracking persons-of-interest via adaptive discriminative features[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part V 14. Springer, 2016: 415-433.

[105] ZHAO K, IMASEKI T, MOURI H, et al. From certain to uncertain: Toward optimal solution for offline multiple object tracking[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE, 2021: 2506-2513.

[106] YANG F, CHANG X, SAKTI S, et al. ReMOT: A model-agnostic refinement for multiple object tracking[J]. Image and Vision Computing, 2021, 106: 104091.

[107] QI C R, ZHOU Y, NAJIBI M, et al. Offboard 3d object detection from point cloud sequences [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 6134-6144.

[108] YANG B, BAI M, LIANG M, et al. Auto4d: Learning to label 4d objects from sequential point clouds[A]. 2021.

[109] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the kitti vision benchmark suite[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2012: 3354-3361.

[110] THRUN S. Probabilistic robotics[J]. Communications of the ACM, 2002, 45(3): 52-57.

[111] KUHN H W. The Hungarian method for the assignment problem[J]. Naval research logistics quarterly, 1955, 2(1-2): 83-97.

[112] SUN P, KRETZSCHMAR H, DOTIWALLA X, et al. Scalability in Perception for Autonomous Driving: Waymo Open Dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020.

[113] CAESAR H, BANKITI V, LANG A H, et al. nuScenes: A multimodal dataset for autonomous driving[C]//CVPR. 2020.

[114] GÄHLERT N, JOURDAN N, CORDTS M, et al. Cityscapes 3d: Dataset and benchmark for 9 dof vehicle detection[A]. 2020.

[115] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]// Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer, 2014: 740-755.

[116] LI Y, HUANG C, NEVATIA R. Learning to associate: Hybridboosted multi-target tracker for crowded scene[C]//2009 IEEE conference on computer vision and pattern recognition. IEEE, 2009: 2953-2960.

[117] BERNARDIN K, STIEFELHAGEN R. Evaluating multiple object tracking performance: the clear mot metrics[J]. EURASIP Journal on Image and Video Processing, 2008, 2008: 1-10.

[118] LEAL-TAIXé L, MILAN A, REID I, et al. MOTChallenge 2015: Towards a Benchmark for Multi-Target Tracking[A/OL]. 2015. http://arxiv.org/abs/1504.01942.

[119] MILAN A, LEAL-TAIXé L, REID I, et al. MOT16: A Benchmark for Multi-Object Tracking [A/OL]. 2016. http://arxiv.org/abs/1603.00831.

[120] LUITEN J, OSEP A, DENDORFER P, et al. Hota: A higher order metric for evaluating multi-object tracking[J]. International journal of computer vision, 2021, 129: 548-578.

[121] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.

[122] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 34. 2020: 12993-13000.

[123] FROSSARD D, URTASUN R. End-to-end learning of multi-sensor 3d tracking by detection [C]//2018 IEEE international conference on robotics and automation (ICRA). IEEE, 2018: 635-642.

[124] PERRON L, FURNON V. OR-Tools[CP/OL]. Google(2022-11-25). https://developers.google.com/optimization/.

[125] PASZKE A, GROSS S, CHINTALA S, et al. Automatic differentiation in pytorch[Z]. 2017.

[126] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[A]. 2017.

[127] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database [C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.

[128] PANG S, MORRIS D, RADHA H. CLOCs: Camera-LiDAR object candidates fusion for 3D object detection[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 10386-10393.

[129] PANG S, MORRIS D, RADHA H. Fast-CLOCs: Fast camera-LiDAR object candidates fusion for 3D object detection[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 187-196.

[130] RISTANI E, TOMASI C. Features for multi-target multi-camera tracking and re-identification [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6036-6046.

[131] SOLOVYEV R, WANG W, GABRUSEVA T. Weighted boxes fusion: Ensembling boxes from different object detection models[J]. Image and Vision Computing, 2021, 107: 104117.

[132] NEVEN D, BRABANDERE B D, PROESMANS M, et al. Instance segmentation by jointly optimizing spatial embeddings and clustering bandwidth[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 8837-8845.

[133] ROMERA E, ALVAREZ J M, BERGASA L M, et al. Erfnet: Efficient residual factorized convnet for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 19(1): 263-272.

[134] XU Z, ZHANG W, TAN X, et al. Segment as points for efficient online multi-object tracking and segmentation[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part I 16. Springer, 2020: 264-281.

[135] QI L, JIANG L, LIU S, et al. Amodal instance segmentation with kins dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3014-3023.

[136] WU H, WEN C, SHI S, et al. Virtual Sparse Convolution for Multimodal 3D Object Detection [A]. 2023.

[137] WU H, HAN W, WEN C, et al. 3d multi-object tracking in point clouds based on prediction confidence-guided data association[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(6): 5668-5677.

# 致　谢

回首七年前，我怀抱着一颗好奇的心，来到南科大。在这样一所年轻的大学里，学校默默地注视着我的成长，我也默默地注视着学校的成长。此刻，我将从南科大走向社会，感慨良多。

首先，感谢我的学术导师郝祁副教授为我在科研和生活上提供的宝贵经验。我为五年前成为郝老师的学生而感到庆幸，是郝老师带我进入了自动驾驶领域，并激发了我对自动驾驶感知的研究热情。即使在本科阶段，郝老师每周都花几个小时的时间为我和其他学生们分享他的科研方法和人生经验，用着幽默风趣的言谈举止教会了我们如何进行科研写作、如何调整自己的心态、如何在社会中立足。三年前，疫情阻拦了多数出国学生的道路，是郝老师为我指点迷津和提供帮助。我自愿地留在母校、留在郝老师课题组里继续我在感知方向的研究。在撰写我的第一篇学术论文时，郝老师逐字逐句地帮忙修改，并与我深入地探讨工作背后的科研价值。在论文发表后，郝老师也还帮我继续拓展思路。郝老师的言传身教定会让我受益终生，在此，我向您表示诚挚的感谢和衷心的祝福。

其次，感谢课题组里的其他指导老师们。感谢张美莹老师为我的科研工作与我进行的热烈探讨，还带领组里的同学们进行社团竞赛等活动的举办，您对工作和生活认真负责的态度值得敬佩。感谢李鄂老师在自动驾驶数据集上提供的帮助和指导，让我对自动驾驶的感知工程有了更直观的感受和更深刻的理解。感谢李大川老师带领我完成一个个感知项目，让我在实际的项目接触中学会如何解决工程问题。感谢马睿老师在组会上的深入讨论，让我对科研的方法有了新的思考。

此外，感谢课题组里的同窗们。感谢高瑞、王鹏宇、蓝文兴、刘博文、彭阳，与你们一起的学习生活让我感到轻松愉快。感谢王鹏宇、刘博文、彭阳，在西安的会议交流和旅行为我留下珍贵的回忆。感谢课题组的师兄们，感谢丁光耀和王帅军提供的学术指导，感谢李承阳提供的服务器支持，感谢陈建军与我在学术上的谈论和在球场上的互动，感谢张子健在我实习期间提供的帮助。祝愿在读的各位同学学业有成，祝愿各位师兄工作顺利。

最后，感谢我的家人们，感谢我的父母对我在学习和工作上的大力支持和平日里的亲切问候与陪伴，感谢我的外婆对我的期待与生活上的照料。希望你们身体健康，万事顺意。

# 个人简历、在学期间完成的相关学术成果

## 个人简历

1998 年 11 月 12 日出生于广东深圳。

2016 年 9 月考入南方科技大学计算机科学与工程系计算机科学与技术专业，2020 年 7 月本科毕业并获得工程学学士学位。

2020 年 9 月至今，在南方科技大学计算机科学与工程系电子科学与技术专业攻读工学硕士学位。

工作经历：2022 年 7 月至 2022 年 9 月，在华为技术有限公司上海研究所智能汽车解决方案事业部实习。

## 在学期间完成的相关学术成果

### 学术论文

[1] Huang K, Hao Q. Joint multi-object detection and tracking with camera-LiDAR fusion for autonomous driving[A]. 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)[C]. 2021: 6983-6989. (国际会议论文, 对应学位论文第三章.)